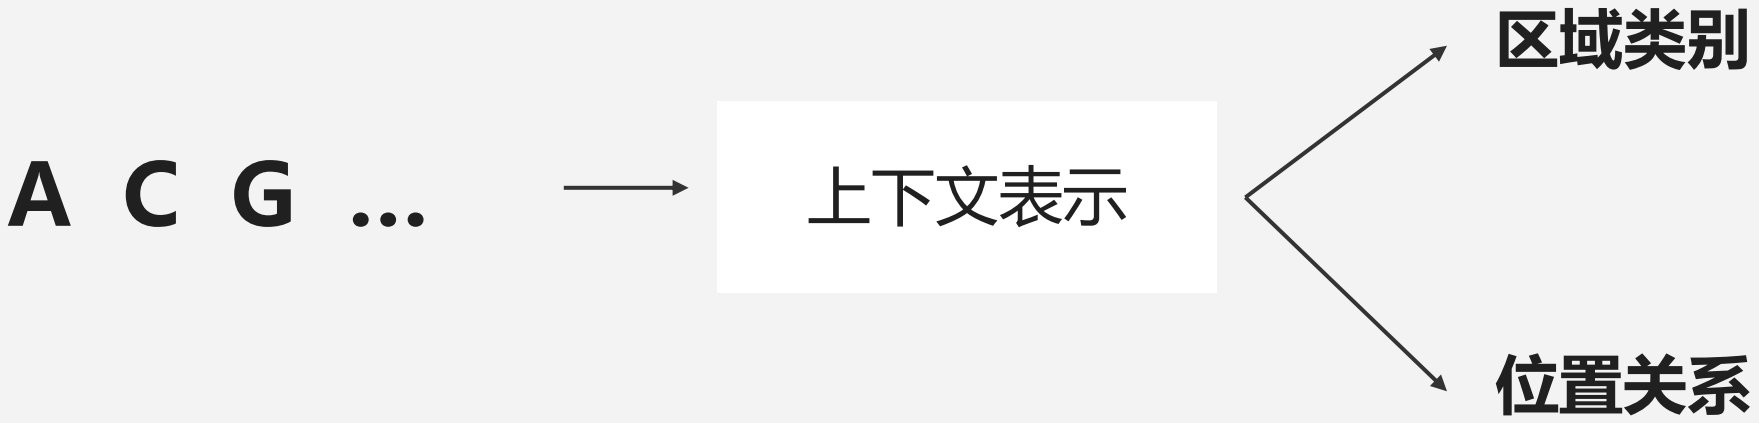
DNA/RNA 与生物序列建模

DNA、RNA序列怎样进入大模型
Nucleotide Transformer、Evo 2 与 RiNALMo

本课要回答的问题

序列先转成上下文表示，再连接不同生物任务。

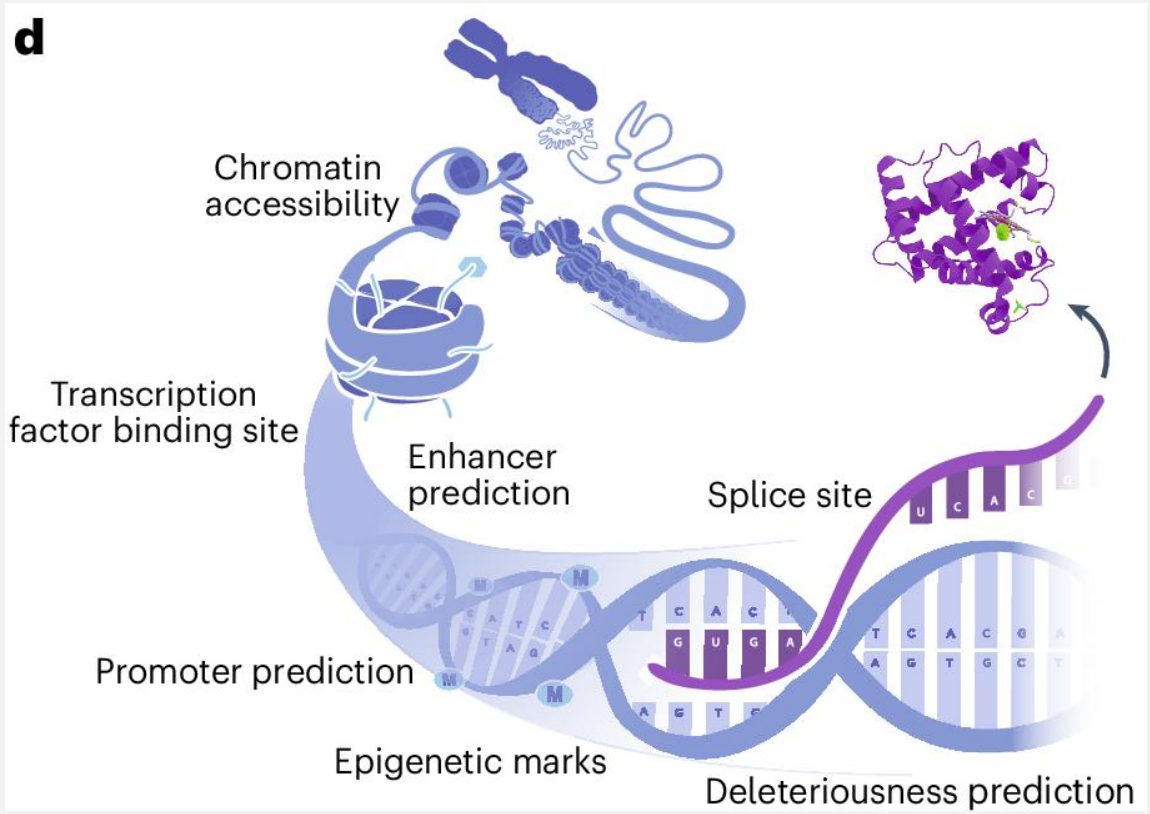
核酸序列



相同编码器可连接不同输出；任务头与标签共同决定具体用途

Wang et al., ACL 2025

DNA、RNA 与蛋白质



DNA记录遗传信息，
RNA参与表达与调控

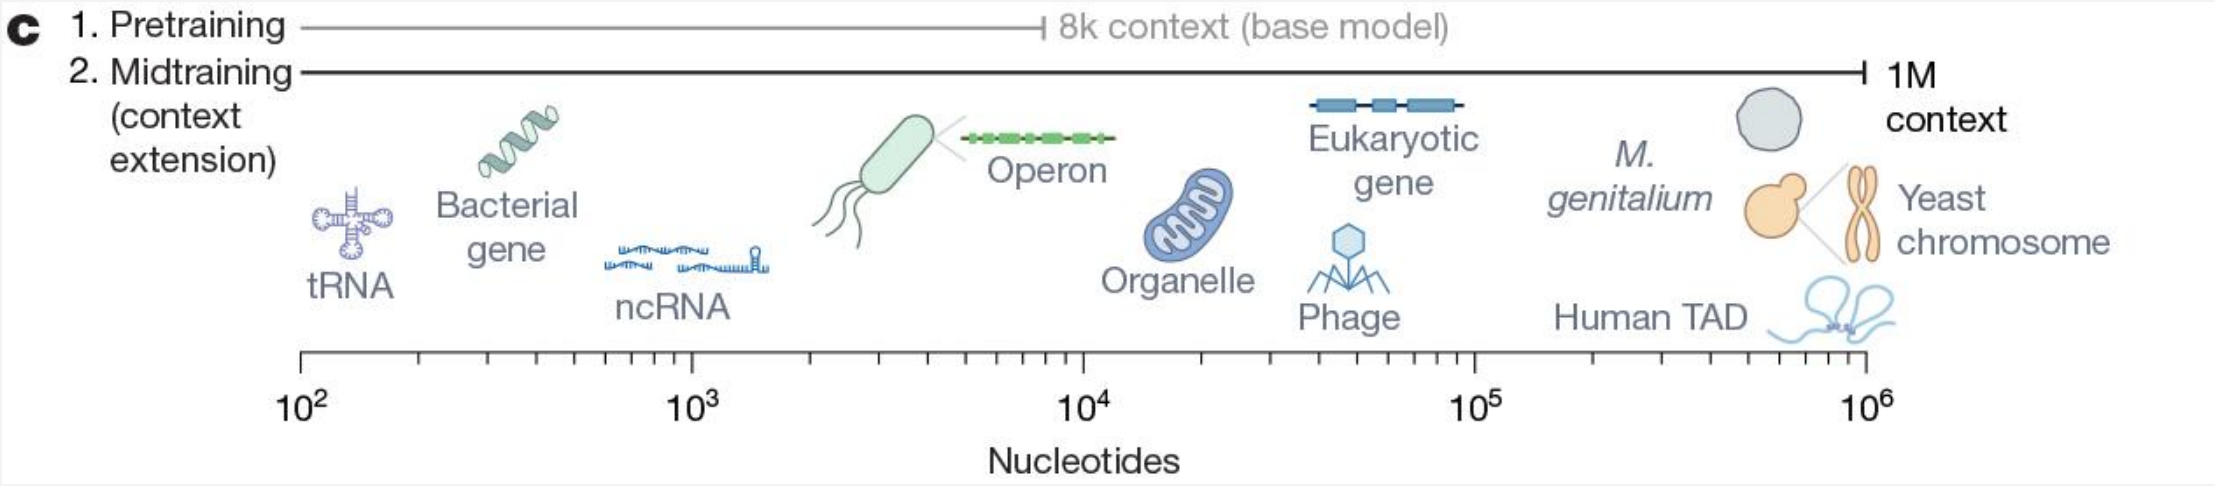
蛋白质承担结构、催化等功能

DNA局部区域对应调控、剪接等不同任务

Dalla-Torre et al., Nat. Methods 2025

序列窗口决定模型能看到什么

窗口长度决定可见范围，长程上下文连接局部与远端区域。



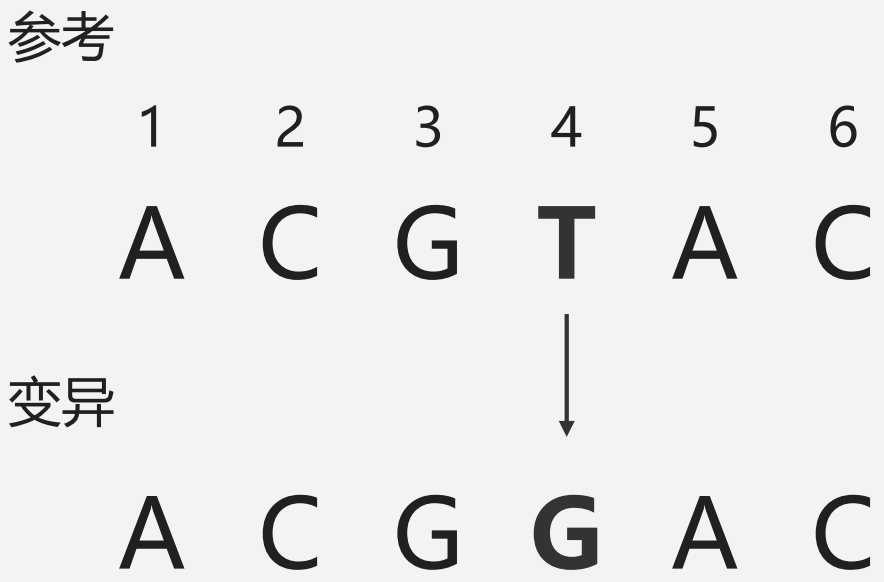
从局部RNA、基因到染色体，所需上下文尺度逐渐增大

Evo 2, Nature 2026

一次T→G替换怎样进入模型

第4位由T替换成G

比较两条序列的表示或任务得分



Dalla-Torre et al., Nat. Methods 2025 · DNA模型评测, Nat. Commun. 2025

序列如何变成 token

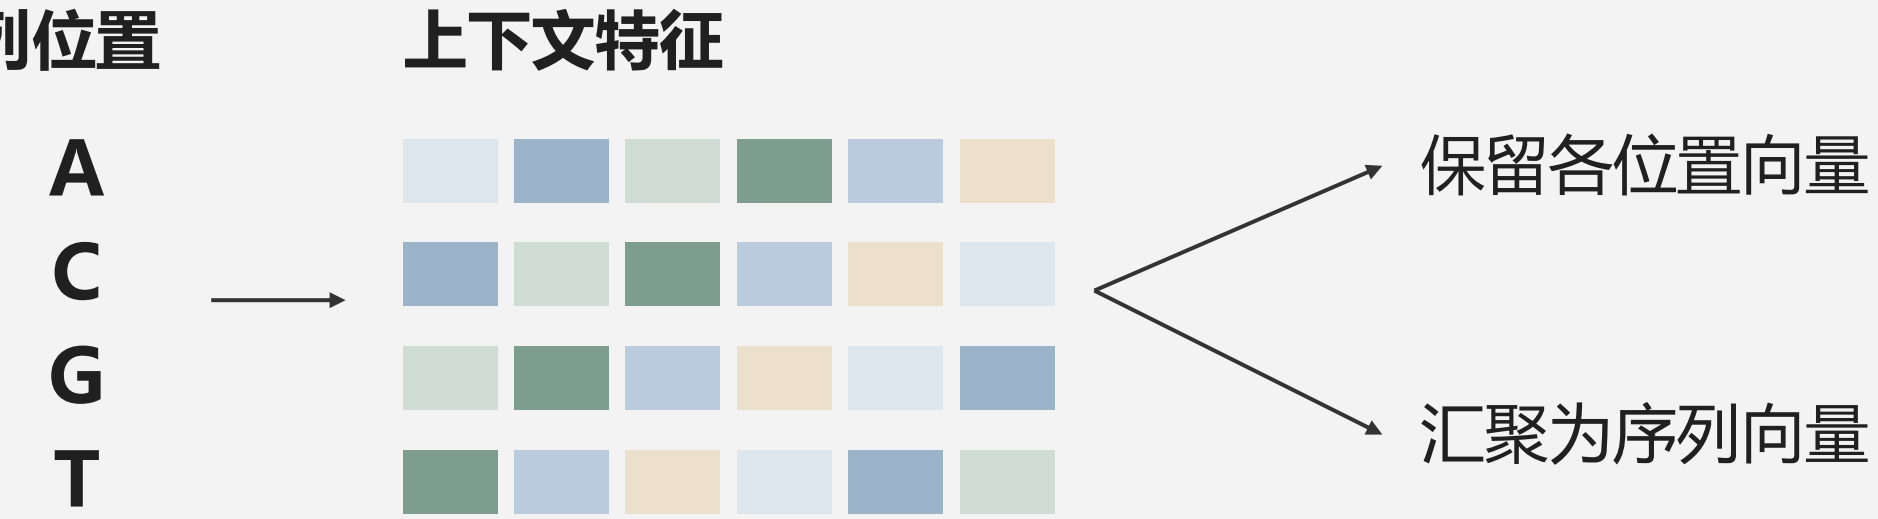
同一条序列可按单碱基、固定片段或子词切分。

切分方式	ACGTAC 的表示	单元数
单碱基	A C G T A C	6
连续 3-mer	ACG / TAC	2
连续 6-mer	ACGTAC	1

Dalla-Torre et al., Nat. Methods 2025 · RiNALMo, Nat. Commun. 2025

token怎样变成上下文向量

同一token在不同上下文中，可以形成不同向量。



保留位置维度可做位点预测，汇聚后可描述整段序列

Dalla-Torre et al., Nat. Methods 2025

掩码预训练学到什么

模型根据可见上下文，恢复被遮盖位置。

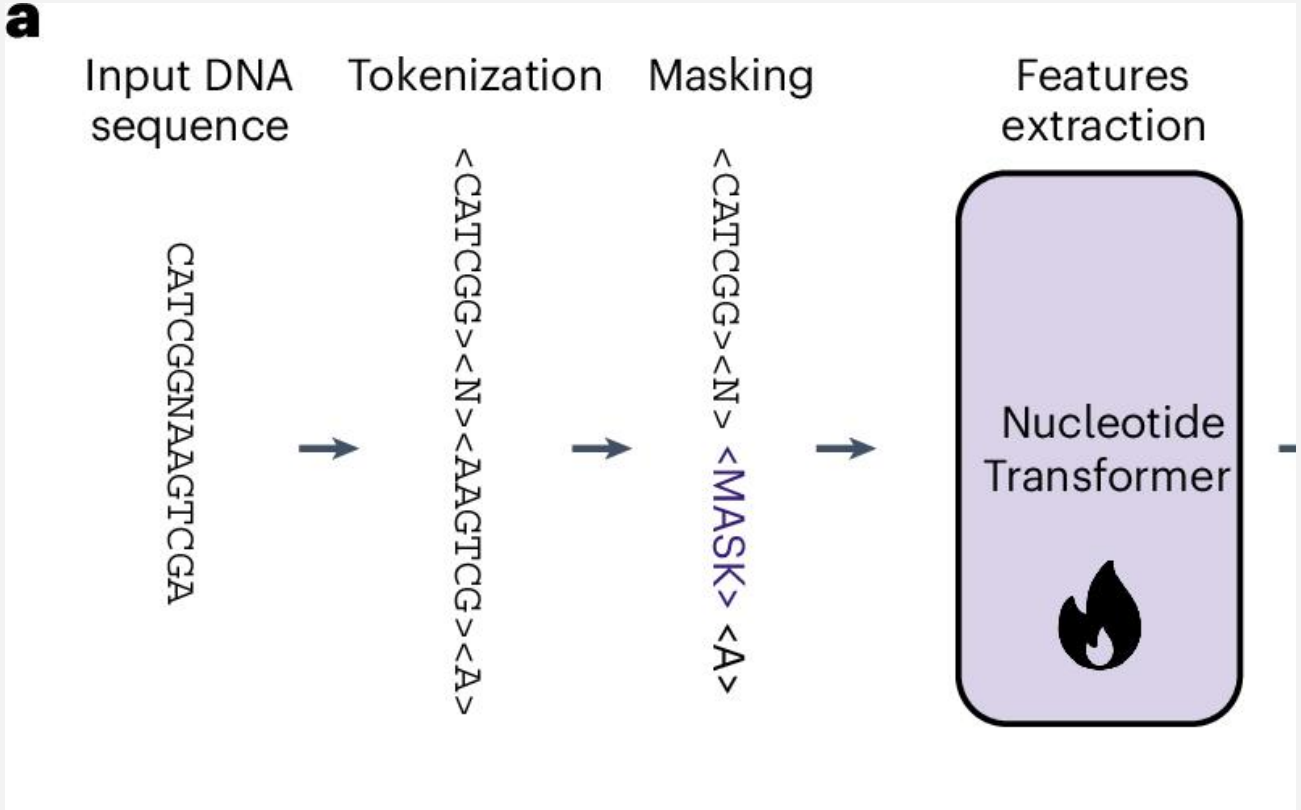
A C ? T A C

利用两侧上下文预测第三位；恢复目标为 G

训练标签来自原序列；优化目标是提高被遮盖碱基的预测概率。

Dalla-Torre et al., Nat. Methods 2025 · RiNALMo, Nat. Commun. 2025

一次掩码训练怎样产生学习信号



原序列提供被遮盖位置的目标

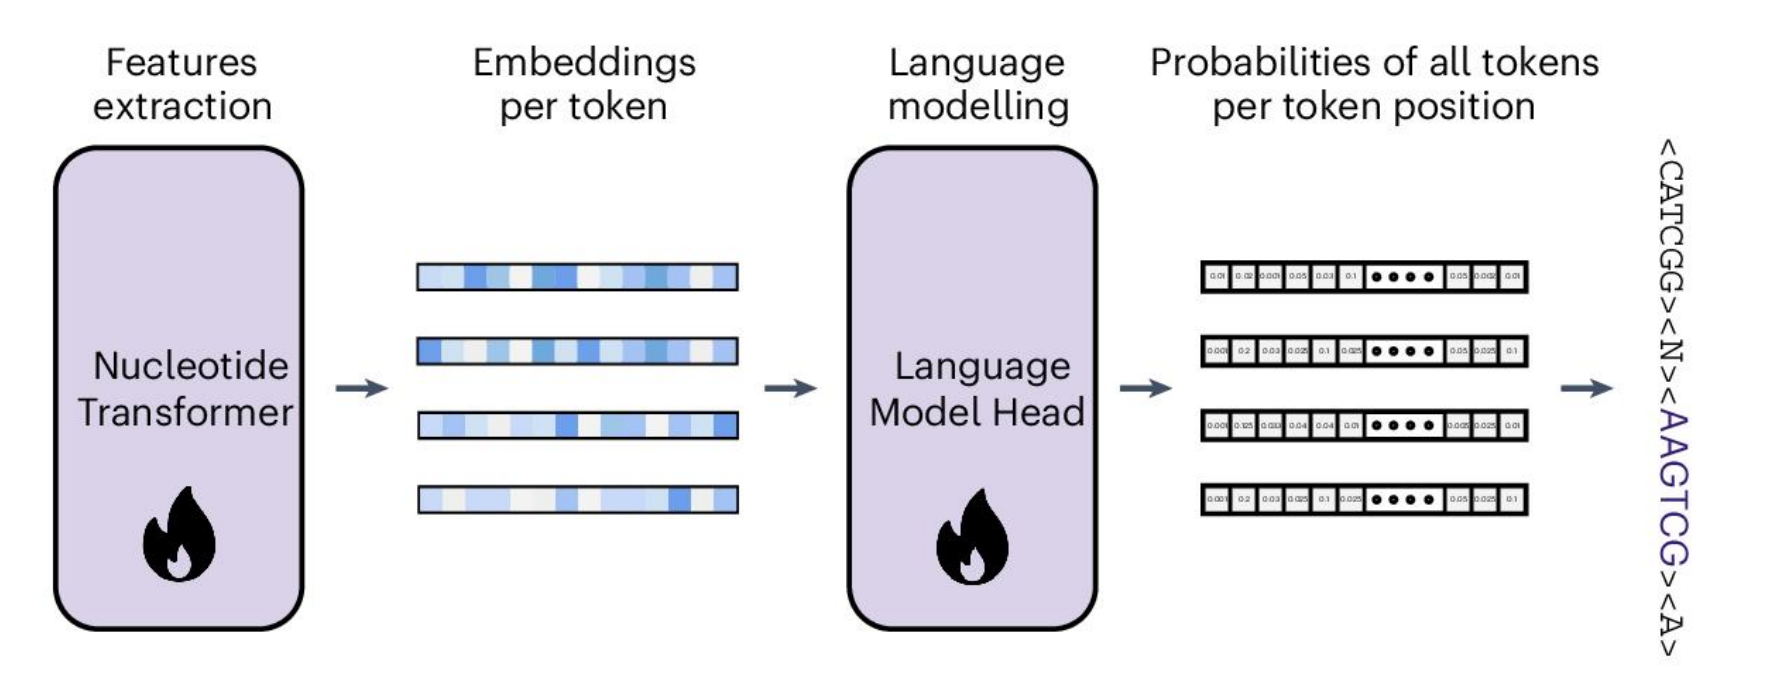
大量遮盖组合形成自监督训练样本

切分、遮盖与上下文编码

Dalla-Torre et al., Nat. Methods 2025

Nucleotide Transformer

NT把DNA上下文编码为位置级向量。



位置级表示接入语言模型头，恢复被遮盖token

Dalla-Torre et al., Nat. Methods 2025

NT的表示可以接到哪些任务

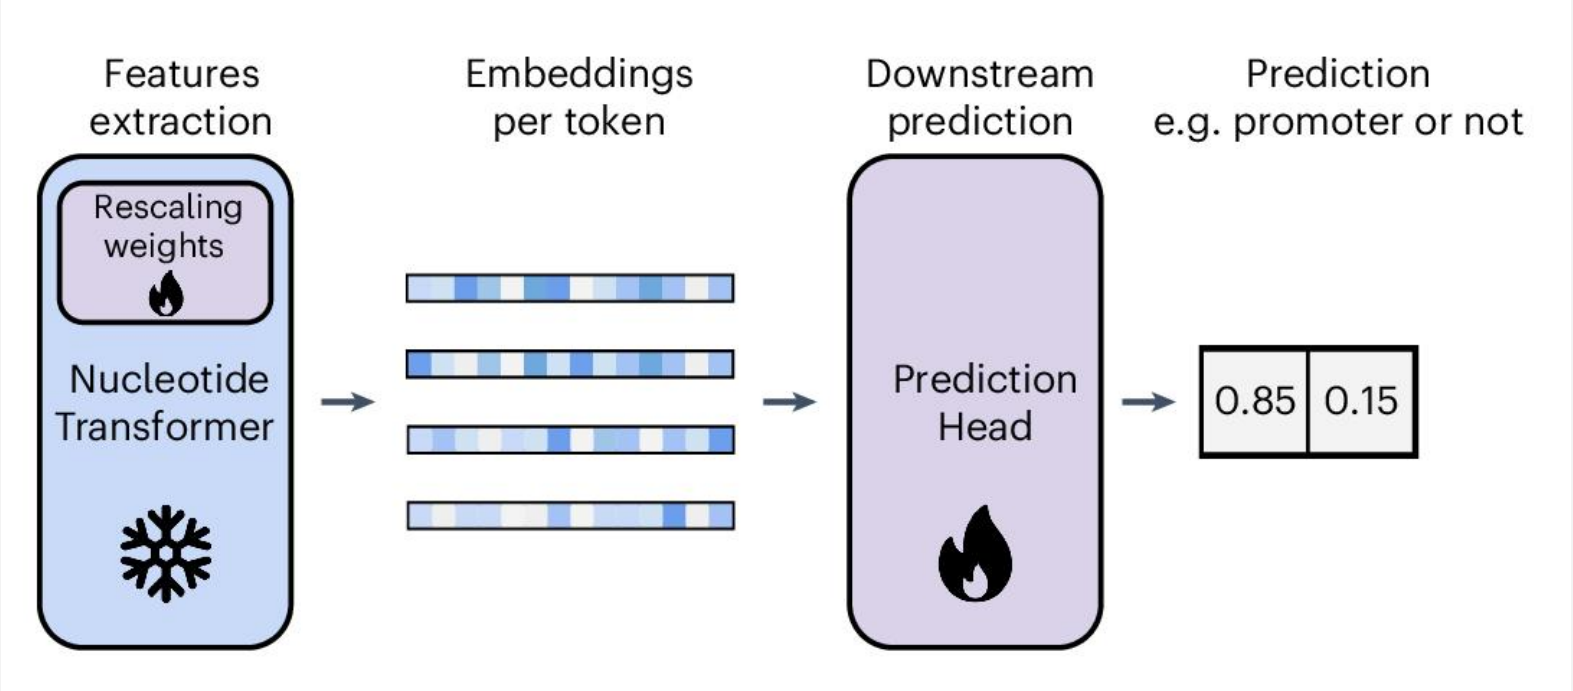
同一个编码器，可以连接不同的任务输出。

任务	输入焦点	输出组织
启动子识别	候选DNA区域	序列级分类
调控区域预测	区域及其上下文	分类或活性回归
剪接位点识别	候选位置附近序列	位置级标签

Dalla-Torre et al., Nat. Methods 2025

从表示到一个任务

冻结编码器后训练预测头，或对编码器进行微调。

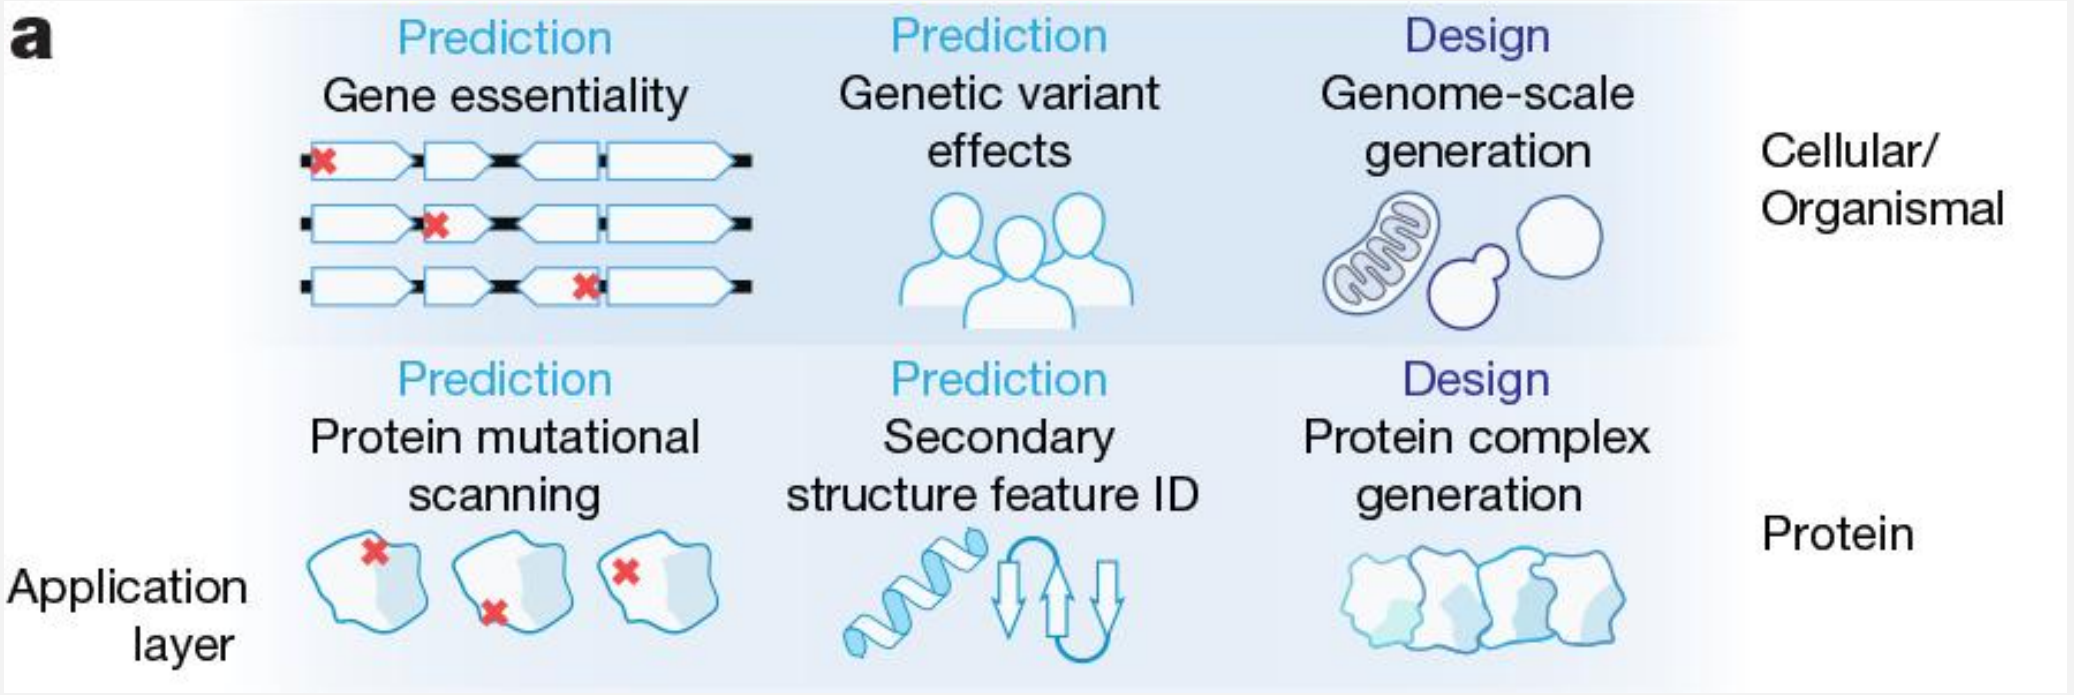


冻结的预训练模块与可训练预测头分工

Dalla-Torre et al., Nat. Methods 2025

Evo 2 的建模方向

Evo 2以基因组序列建模连接变异预测与序列设计。



图中列出基因与蛋白质层面的部分应用方向

Evo 2, Nature 2026

序列概率把局部预测连接起来

序列ACG的概率，按每一位已有的前缀分解。

$$\mathbf{A} \qquad \mathbf{A\,C} \qquad \mathbf{A\,C\,G}$$

$$P(A) \times P(C \mid A) \times P(G \mid AC)$$

生成时逐位采样，评分时沿给定序列累计对数概率

Evo 2, Nature 2026

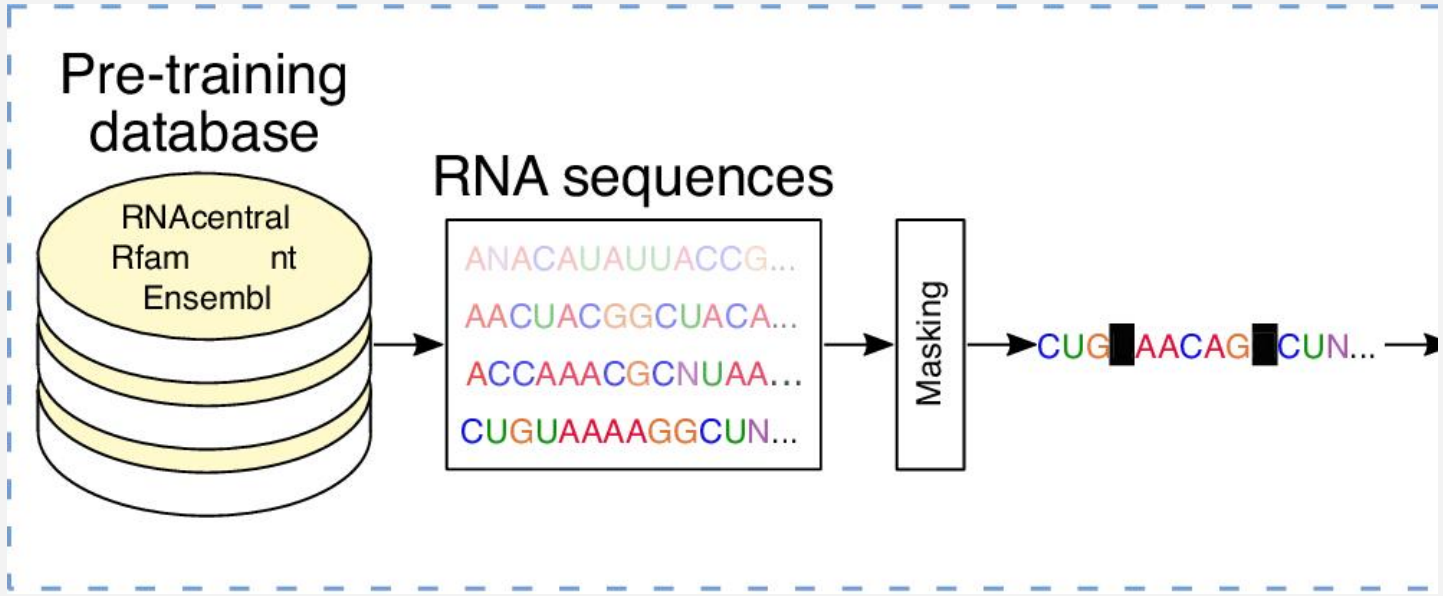
两类预训练任务

遮盖恢复与顺序生成，采用不同的训练目标。

比较维度	Nucleotide Transformer	Evo 2
预训练目标	掩码恢复	生成式序列建模
常见输出	上下文表示	序列评分或生成
选择依据	下游任务与版本	任务、上下文与资源

Dalla-Torre et al., Nat. Methods 2025 · Evo 2, Nature 2026

RNA任务把序列连接到配对关系



RNA有A、U、G、C四种碱基

RiNALMo从RNA上下文学习表示

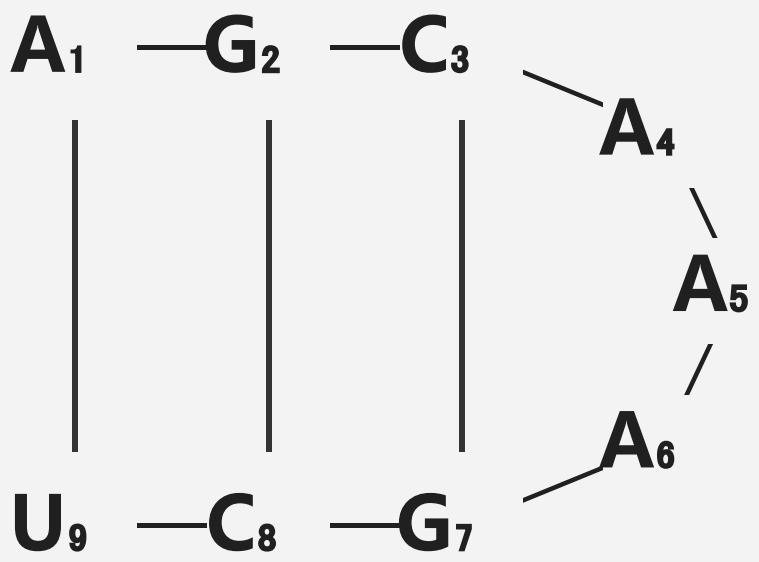
RNA数据经过遮盖后进入上下文编码器

RiNALMo, Nat. Commun. 2025

读懂一条RNA的茎与环

5′ - A G C A A A G C U - 3′

按1—9给碱基编号；骨架线连接相邻位置，配对线连接互补碱基。



茎：由三组碱基配对构成

位置对	碱基对
1—9	A—U
2—8	G—C
3—7	C—G

环区：4—6位的 A A A

RiNALMo, Nat. Commun. 2025

配对表与括号串怎样对应

配对表记录位置关系，括号串沿序列逐位编码。

序列位置	1 2 3	4 5 6	7 8 9
碱基	A G C	A A A	G C U
配对位置	9 8 7	— — —	3 2 1
括号串	(((	. . .	)))

RiNALMo, Nat. Commun. 2025

把位置配对写成二维矩阵

行、列都使用序列位置，相交单元格记录配对。

位置	7：G	8：C	9：U
1：A	0	0	1
2：G	0	1	0
3：C	1	0	0

RiNALMo, Nat. Commun. 2025

让测试集对应新的序列家族

按序列家族划分训练与测试，检验对新家族的泛化。

	训练时可见	测试时的新对象
序列家族	家族A、B	家族C

相近序列所在的家族整体划分，减少训练与测试之间的近邻泄漏

DNA模型评测, Nat. Commun. 2025 · RiNALMo, Nat. Commun. 2025

配对预测的精确率与召回率

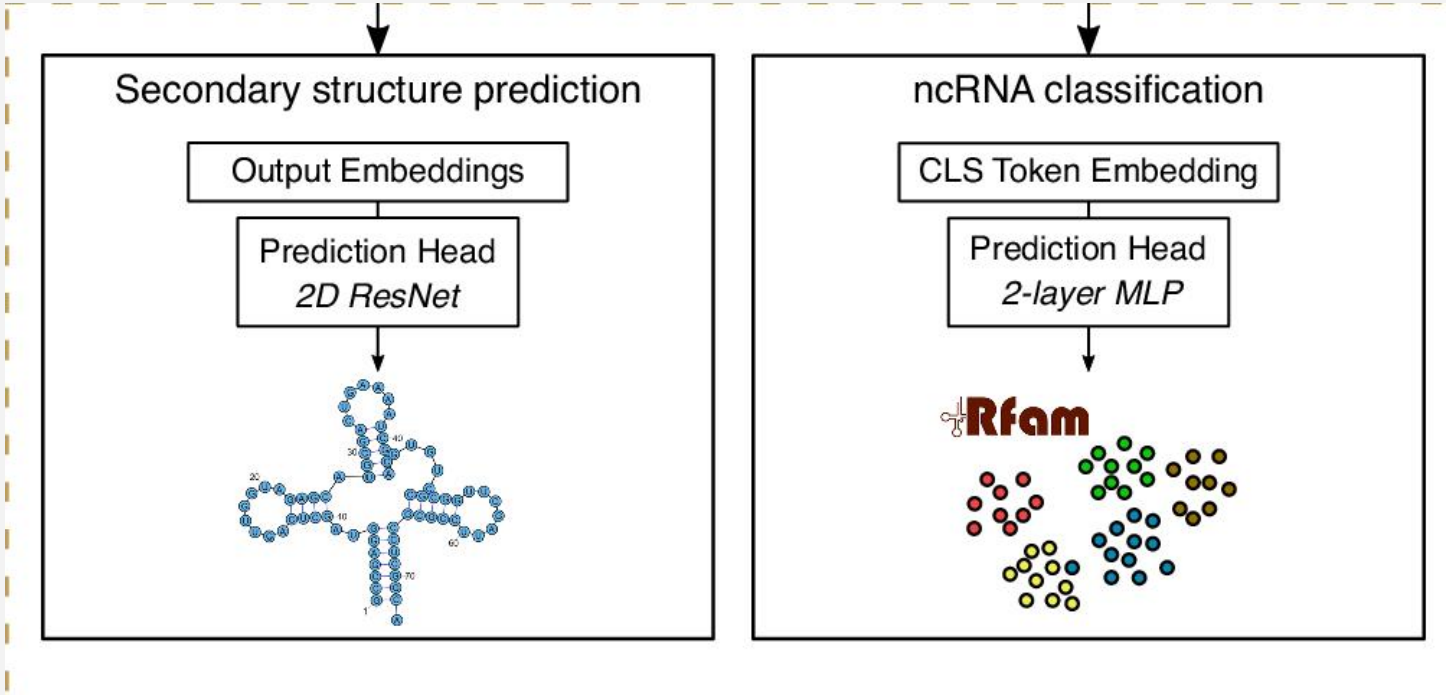
对照预测集合与参考集合，分别计算精确率和召回率。

统计对象	计数	评价结果
正确配对	2组	精确率 = 2/3
预测配对	3组	召回率 = 2/3
参考配对	3组	F1 = 2/3

RiNALMo, Nat. Commun. 2025

RiNALMo的下游任务

RiNALMo的表示可连接结构、分类和表达相关任务。



位置级表示与序列级表示分别连接不同任务头

RiNALMo, Nat. Commun. 2025

本课小结

输入：分子类型、窗口与token

模型：NT、Evo 2、RiNALMo

输出：类别、数值或位置关系

Wang et al., ACL 2025 · Dalla-Torre et al., Nat. Methods 2025 等

延伸阅读

1. Wang et al. Large Language Models in Bioinformatics: A Survey. ACL Findings, 2025

2. Dalla-Torre et al. Nucleotide Transformer: building and evaluating robust foundation models for human genomics. Nature Methods, 2025

3. Genome modelling and design across all domains of life with Evo 2. Nature, 2026

4. Penić et al. RiNALMo: general-purpose RNA language models can generalize well on structure prediction tasks. Nature Communications, 2025

5. Benchmarking DNA foundation models for genomic and genetic tasks. Nature Communications, 2025