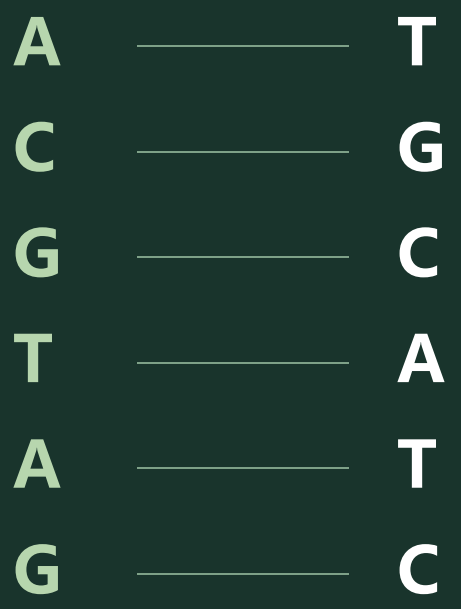
BIOLOGICAL
FOUNDATION MODELS

DNA / RNA 与生物序列建模



DNA、RNA序列怎样进入大模型
Nucleotide Transformer、Evo 2 与 RiNALMo

SEQUENCE

本课要回答的问题

序列先转成上下文表示，再连接不同生物任务。

核酸序列

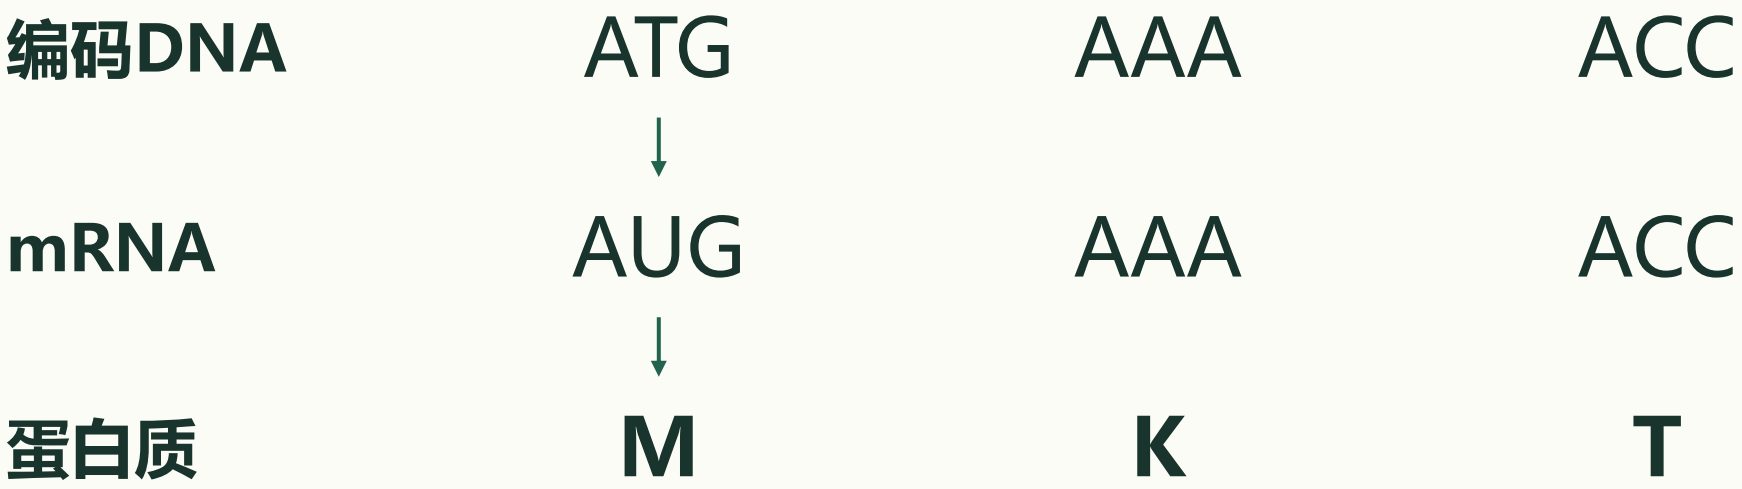


相同编码器可连接不同输出；任务头与标签共同决定具体用途

Wang et al., ACL 2025

DNA、RNA 与蛋白质

DNA记录遗传信息，RNA参与表达与调控

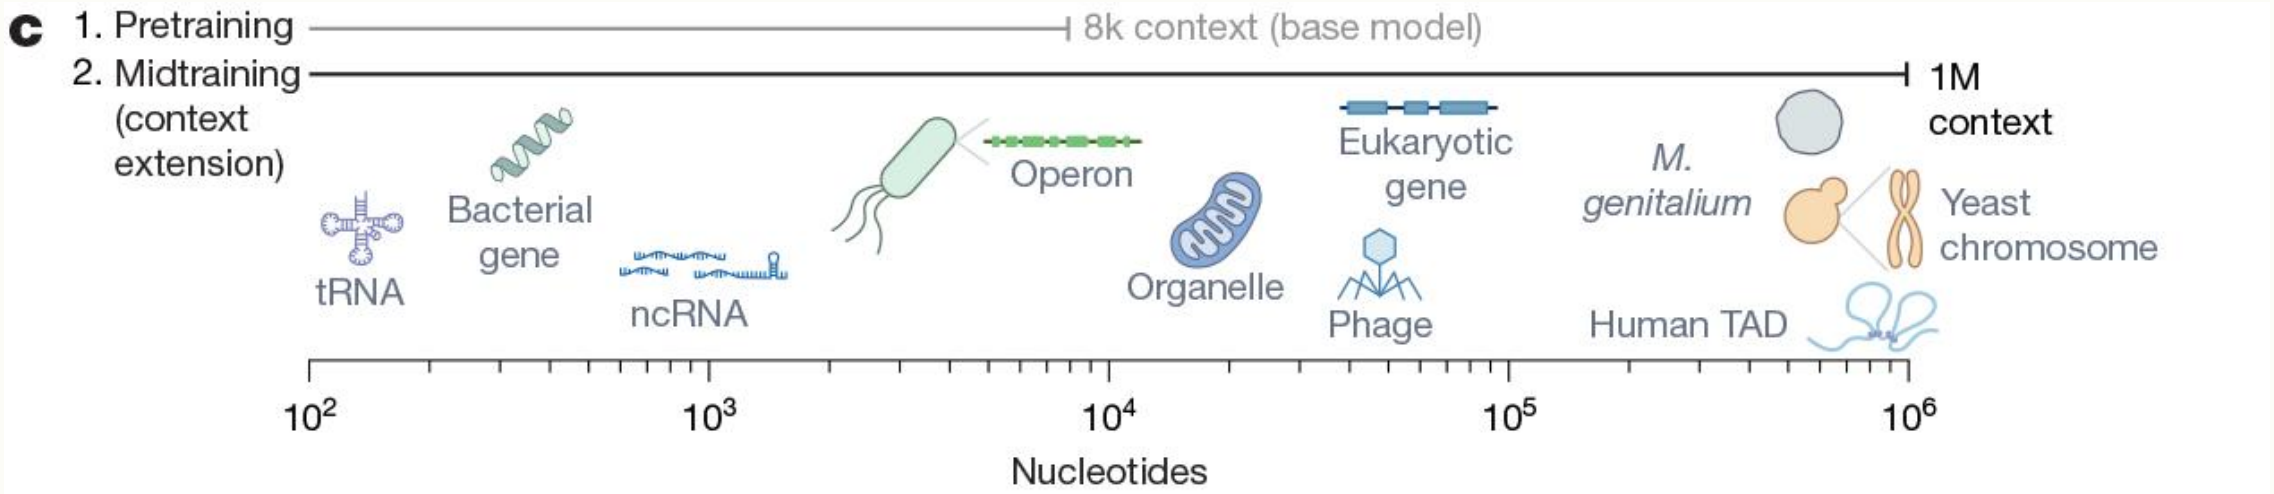


编码链 DNA 经转录与翻译连接到氨基酸序列

Dalla-Torre et al., Nat. Methods 2025

序列窗口决定模型能看到什么

窗口长度决定可见范围，长程上下文连接局部与远端区域。



从局部RNA、基因到染色体，所需上下文尺度逐渐增大

Evo 2, Nature 2026

一次T→G替换怎样进入模型

第4位由T替换成G

比较两条序列的表示或任务得分



Dalla-Torre et al., Nat. Methods 2025 · DNA模型评测, Nat. Commun. 2025

序列如何变成 token

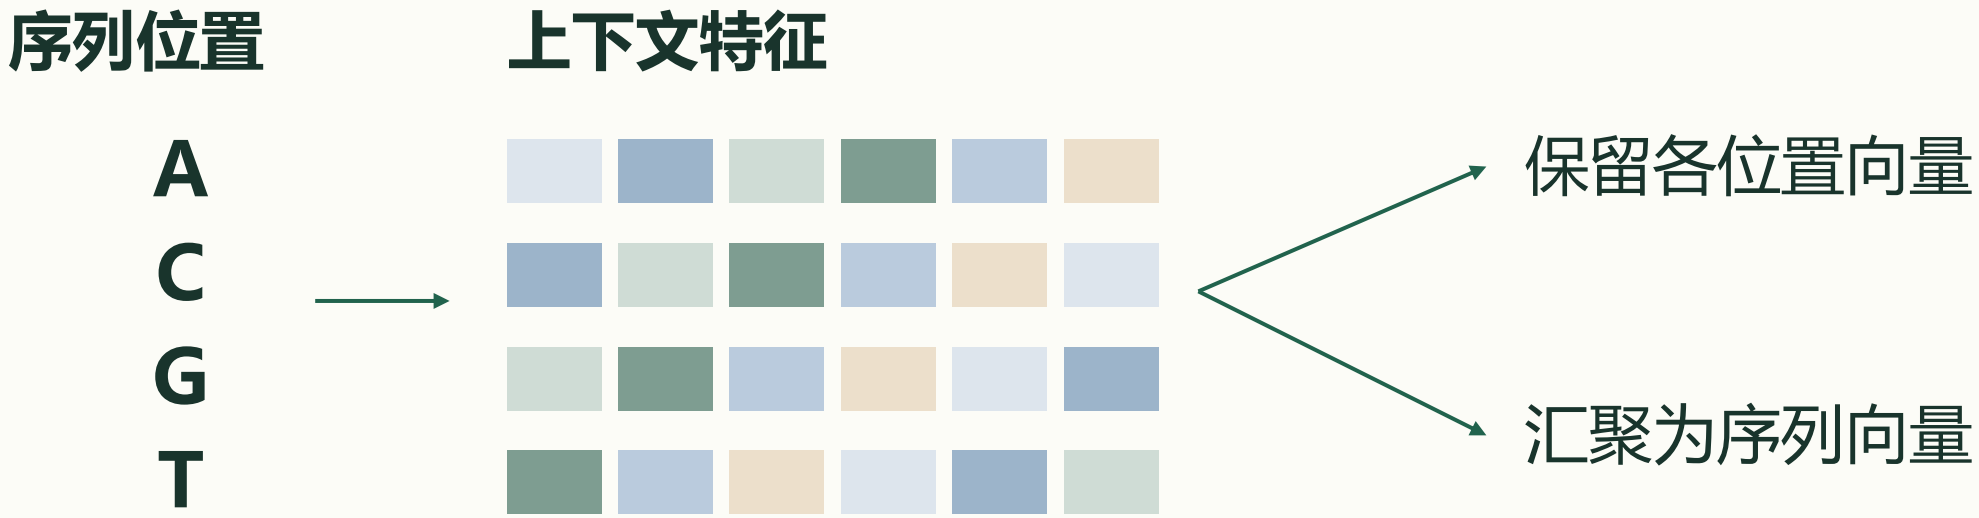
同一条序列可按单碱基、固定片段或子词切分。

切分方式	ACGTAC 的表示	单元数
单碱基	A C G T A C	6
连续 3-mer	ACG / TAC	2
连续 6-mer	ACGTAC	1

Dalla-Torre et al., Nat. Methods 2025 · RiNALMo, Nat. Commun. 2025

token怎样变成上下文向量

同一token在不同上下文中，可以形成不同向量。



保留位置维度可做位点预测，汇聚后可描述整段序列

Dalla-Torre et al., Nat. Methods 2025

掩码预训练学到什么

模型根据可见上下文，恢复被遮盖位置。

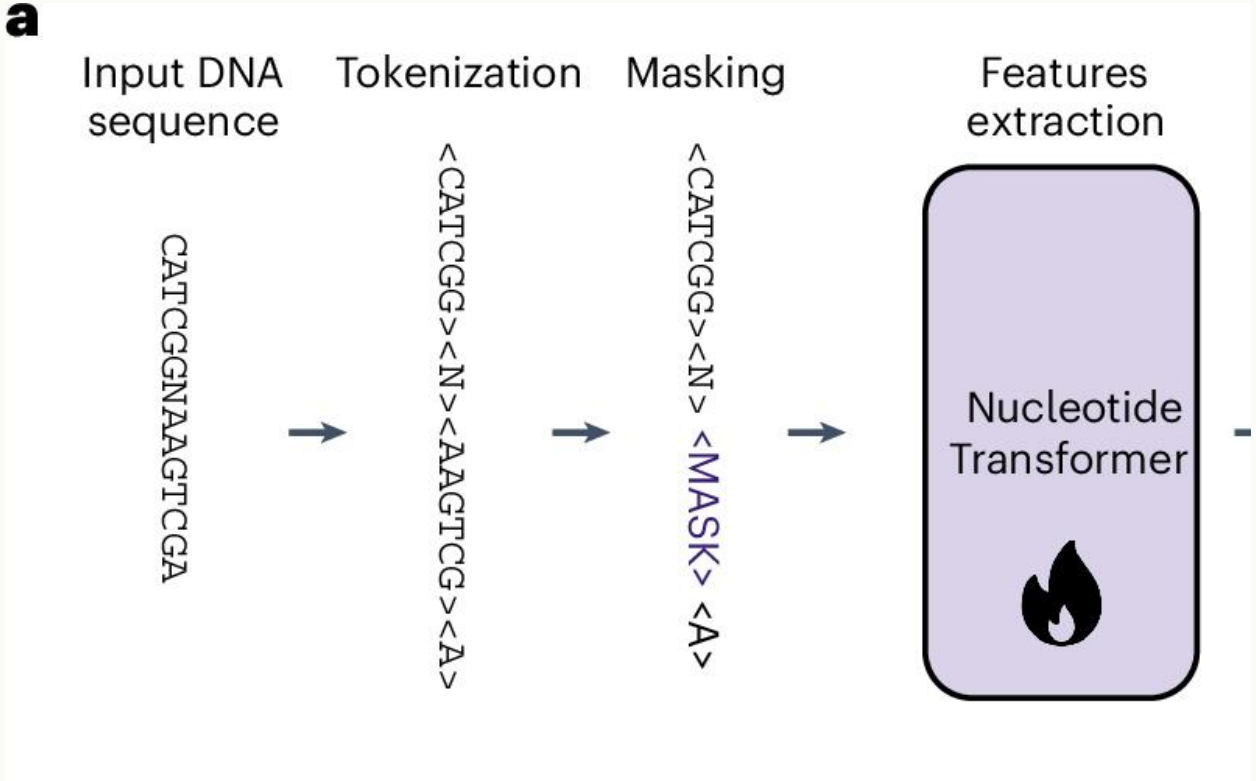
A C ? T A C

利用两侧上下文预测第三位；恢复目标为 G

训练标签来自原序列；优化目标是提高被遮盖碱基的预测概率。

Dalla-Torre et al., Nat. Methods 2025 · RiNALMo, Nat. Commun. 2025

一次掩码训练怎样产生学习信号



原序列提供被遮盖位置的目标

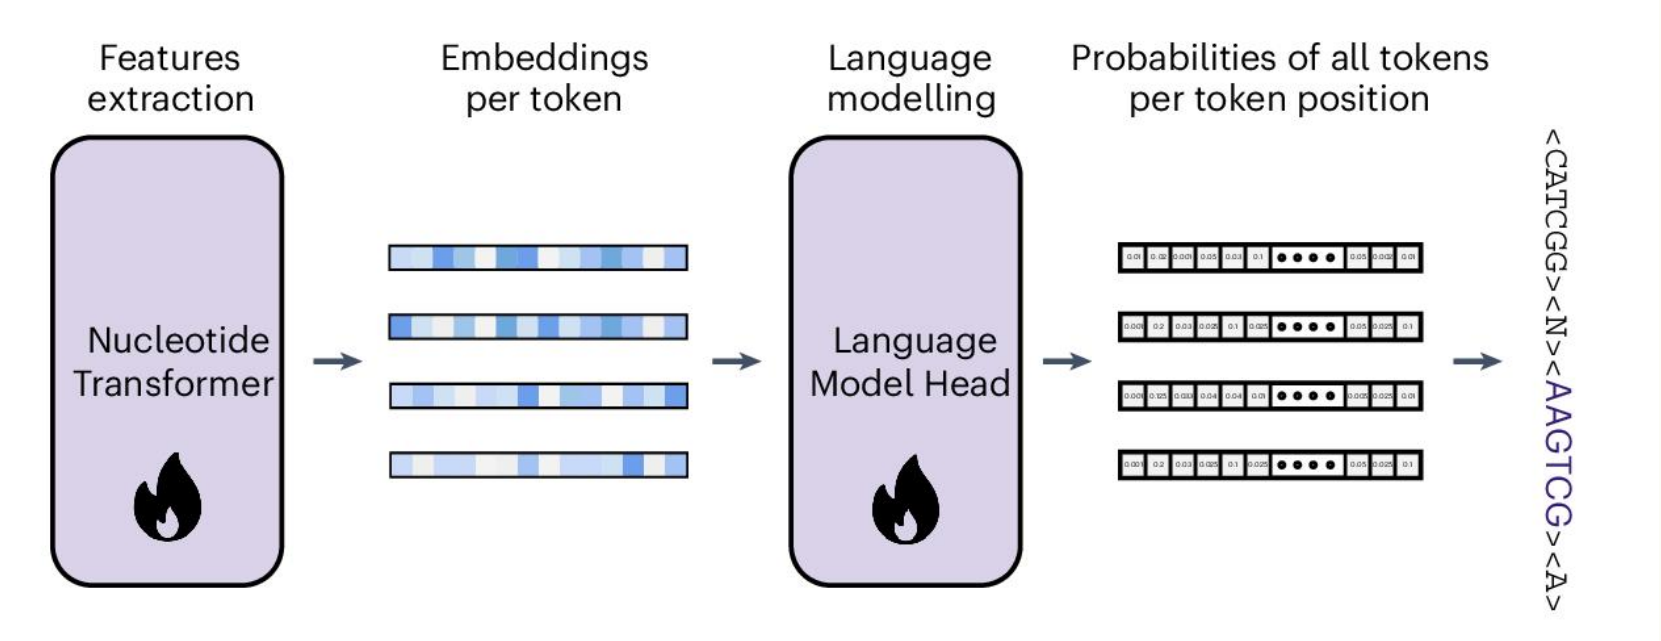
大量遮盖组合形成自监督训练样本

切分、遮盖与上下文编码

Dalla-Torre et al., Nat. Methods 2025

Nucleotide Transformer

NT把DNA上下文编码为位置级向量。



位置级表示接入语言模型头，恢复被遮盖token

Dalla-Torre et al., Nat. Methods 2025

NT的表示可以接到哪些任务

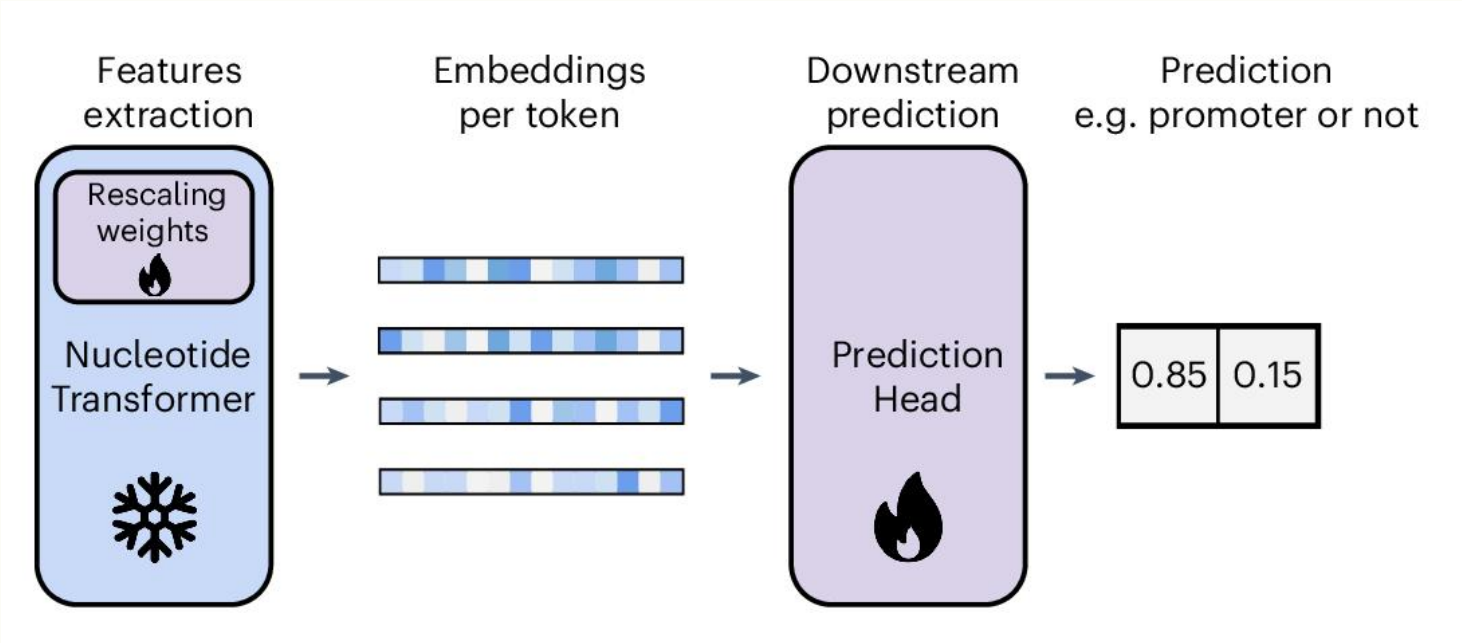
同一个编码器，可以连接不同的任务输出。

任务	输入焦点	输出组织
启动子识别	候选DNA区域	序列级分类
调控区域预测	区域及其上下文	分类或活性回归
剪接位点识别	候选位置附近序列	位置级标签

Dalla-Torre et al., Nat. Methods 2025

从表示到一个任务

冻结编码器后训练预测头，或对编码器进行微调。

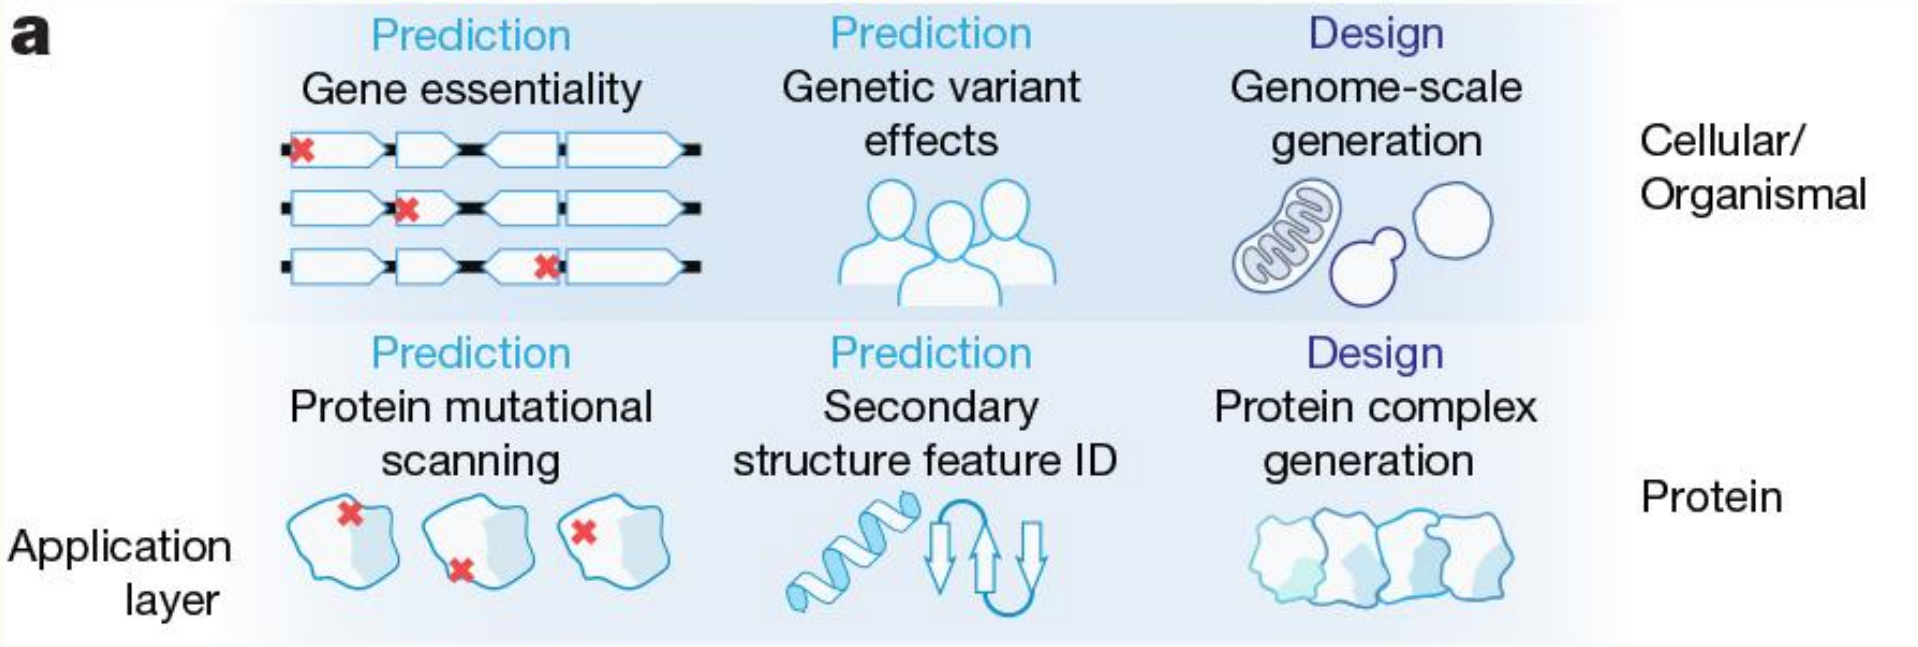


冻结的预训练模块与可训练预测头分工

Dalla-Torre et al., Nat. Methods 2025

Evo 2 的建模方向

Evo 2以基因组序列建模连接变异预测与序列设计。



图中列出基因与蛋白质层面的部分应用方向

Evo 2, Nature 2026

序列概率把局部预测连接起来

序列ACG的概率，按每一位已有的前缀分解。

$$P(\mathbf{A}) \times P(\mathbf{C} \mid \mathbf{A}) \times P(\mathbf{G} \mid \mathbf{AC})$$

$\mathbf{A}$ $\mathbf{A\,C}$ $\mathbf{A\,C\,G}$

生成时逐位采样，评分时沿给定序列累计对数概率

Evo 2, Nature 2026

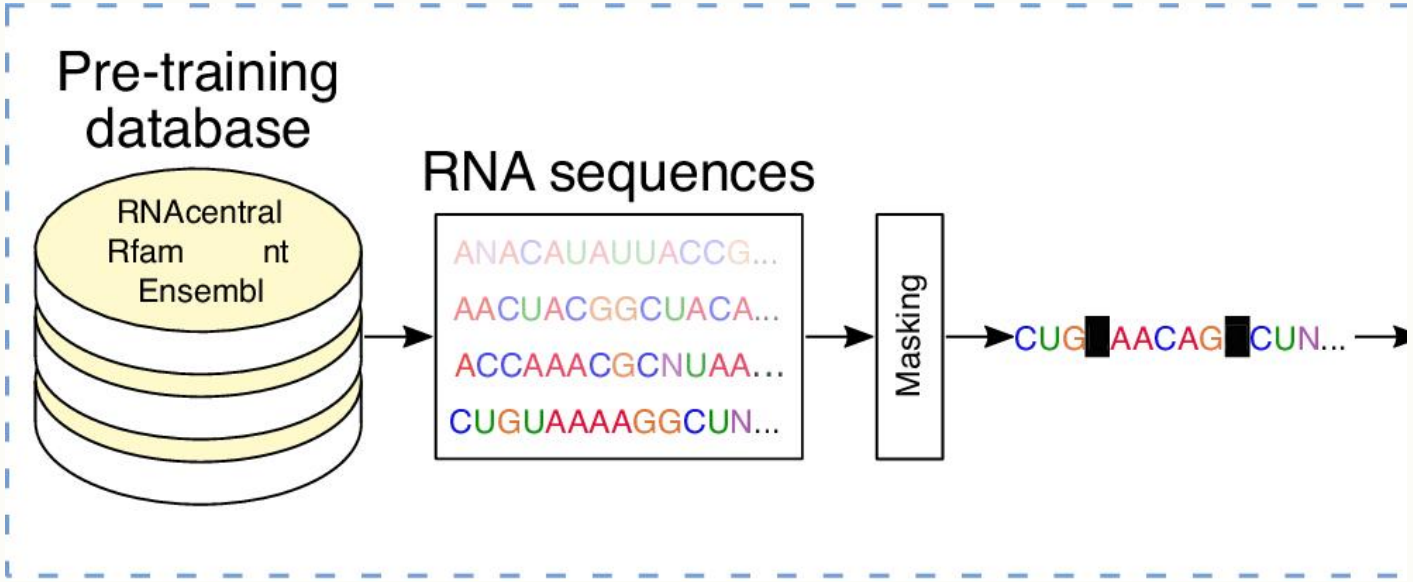
两类预训练任务

遮盖恢复与顺序生成，采用不同的训练目标。

比较维度	Nucleotide Transformer	Evo 2
预训练目标	掩码恢复	生成式序列建模
常见输出	上下文表示	序列评分或生成
选择依据	下游任务与版本	任务、上下文与资源

Dalla-Torre et al., Nat. Methods 2025 · Evo 2, Nature 2026

RNA任务把序列连接到配对关系



RNA有A、U、G、C四种碱基

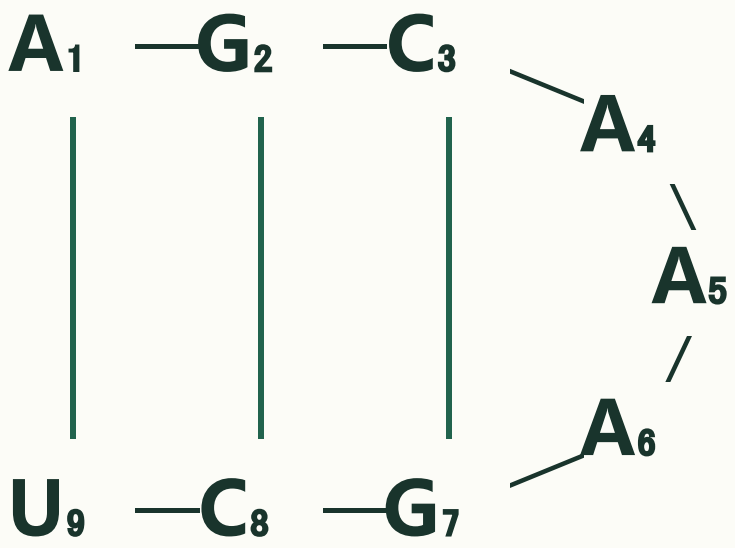
RiNALMo从RNA上下文学习表示

RNA数据经过遮盖后进入上下文编码器

RiNALMo, Nat. Commun. 2025

读懂一条RNA的茎与环

5′ A G C A A A G C U 3′



茎区：互补配对

位置	碱基
1—9	A—U
2—8	G—C
3—7	C—G

环区：第 4—6 位

RiNALMo, Nat. Commun. 2025

配对表与括号串怎样对应

配对表记录位置关系，括号串沿序列逐位编码。

序列位置	1 2 3	4 5 6	7 8 9
碱基	A G C	A A A	G C U
配对位置	9 8 7	— — —	3 2 1
括号串	(((	. . .	)))

RiNALMo, Nat. Commun. 2025

把位置配对写成二维矩阵

行、列都使用序列位置，相交单元格记录配对。

位置	7：G	8：C	9：U
1：A	0	0	1
2：G	0	1	0
3：C	1	0	0

RiNALMo, Nat. Commun. 2025

让测试集对应新的序列家族

按序列家族划分训练与测试，检验对新家族的泛化。

	训练时可见	测试时的新对象
序列家族	家族A、B	家族C

相近序列所在的家族整体划分，减少训练与测试之间的近邻泄漏

DNA模型评测, Nat. Commun. 2025 · RiNALMo, Nat. Commun. 2025

配对预测的精确率与召回率

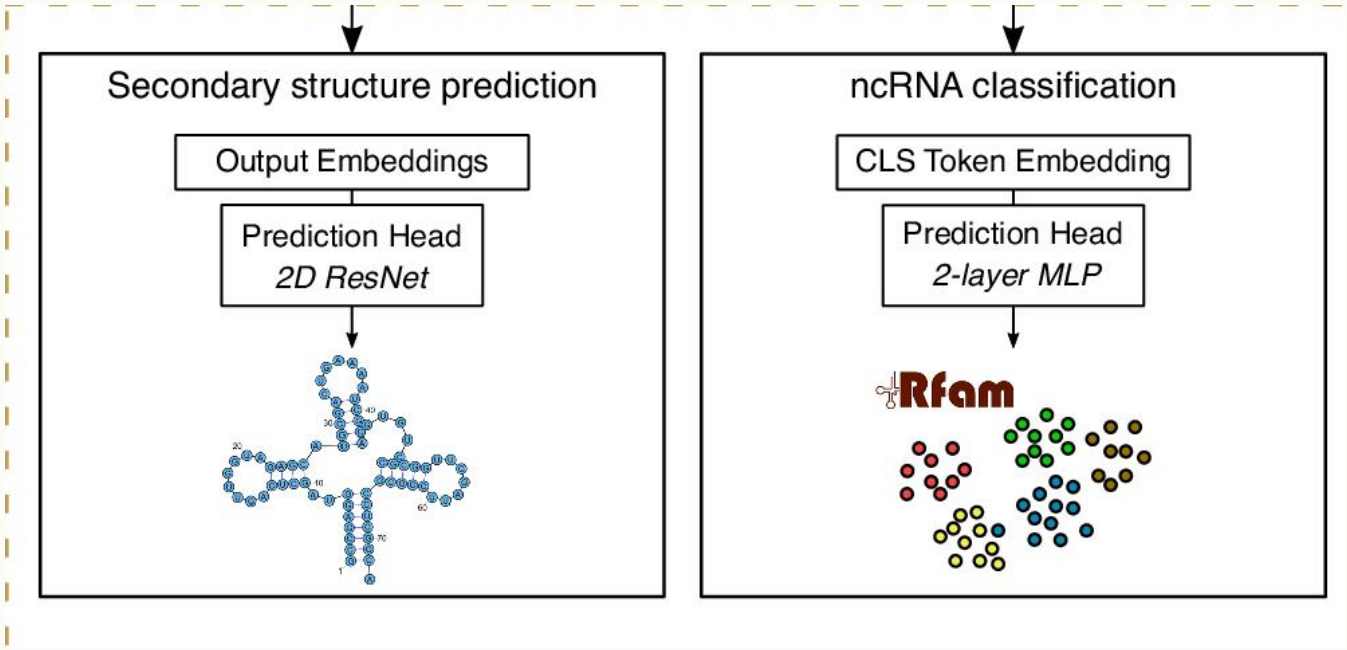
对照预测集合与参考集合，分别计算精确率和召回率。

统计对象	计数	评价结果
正确配对	2组	精确率 = 2/3
预测配对	3组	召回率 = 2/3
参考配对	3组	F1 = 2/3

RiNALMo, Nat. Commun. 2025

RiNALMo的下游任务

RiNALMo的表示可连接结构、分类和表达相关任务。



位置级表示与序列级表示分别连接不同任务头

RiNALMo, Nat. Commun. 2025

本课小结

输入

分子类型、窗口与token

模型

NT、Evo 2、RiNALMo

输出

类别、数值或位置关系

Wang et al., ACL 2025 · Dalla-Torre et al., Nat. Methods 2025 等

延伸阅读

生物信息大模型综述

Wang et al., ACL 2025

Nucleotide Transformer：人类基因组表示

Dalla-Torre et al., Nat. Methods 2025

Evo 2：跨生命领域的基因组建模

Evo 2, Nature 2026

RiNALMo：RNA语言模型与结构预测

RiNALMo, Nat. Commun. 2025

DNA基础模型的基因组任务评测

DNA模型评测, Nat. Commun. 2025