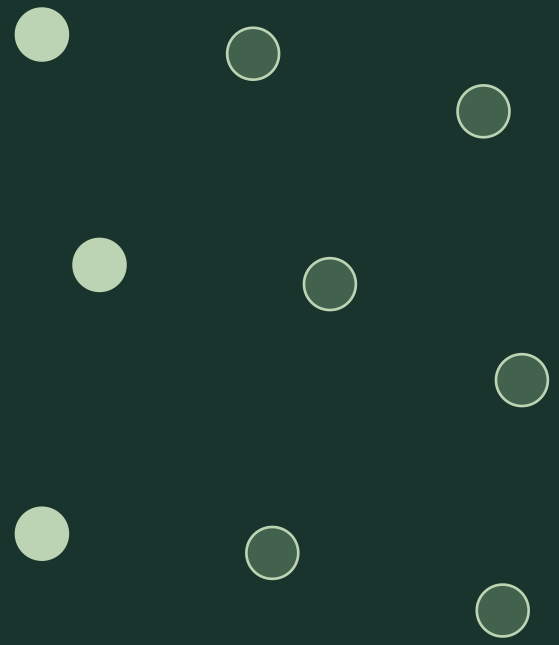
BIOLOGICAL
FOUNDATION MODELS

单细胞与空间模型

从细胞×基因矩阵到细胞表示
scGPT、Geneformer与Nicheformer



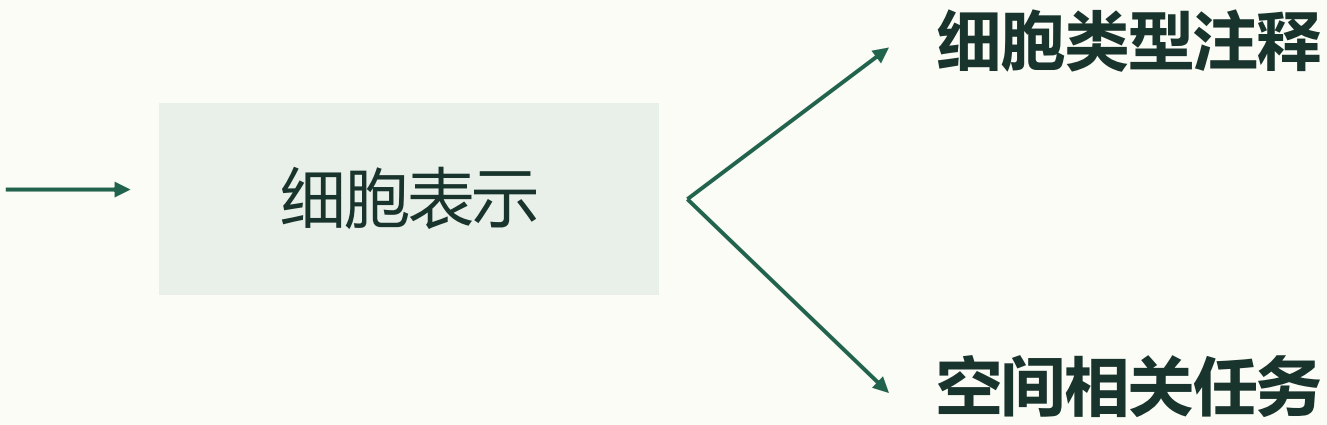
CELLULAR CONTEXT

本课要回答的问题

表达矩阵得到细胞表示后，可以接入不同任务。

表达矩阵

	基因A	基因B
细胞1	8	1
细胞2	1	7



细胞注释预测身份；空间相关任务读取区域或邻域信息

Cui et al., Nat. Methods 2024 · Nicheformer, Nat. Methods 2025

细胞类型与细胞状态

类型描述细胞身份，状态描述当前的活动与变化。

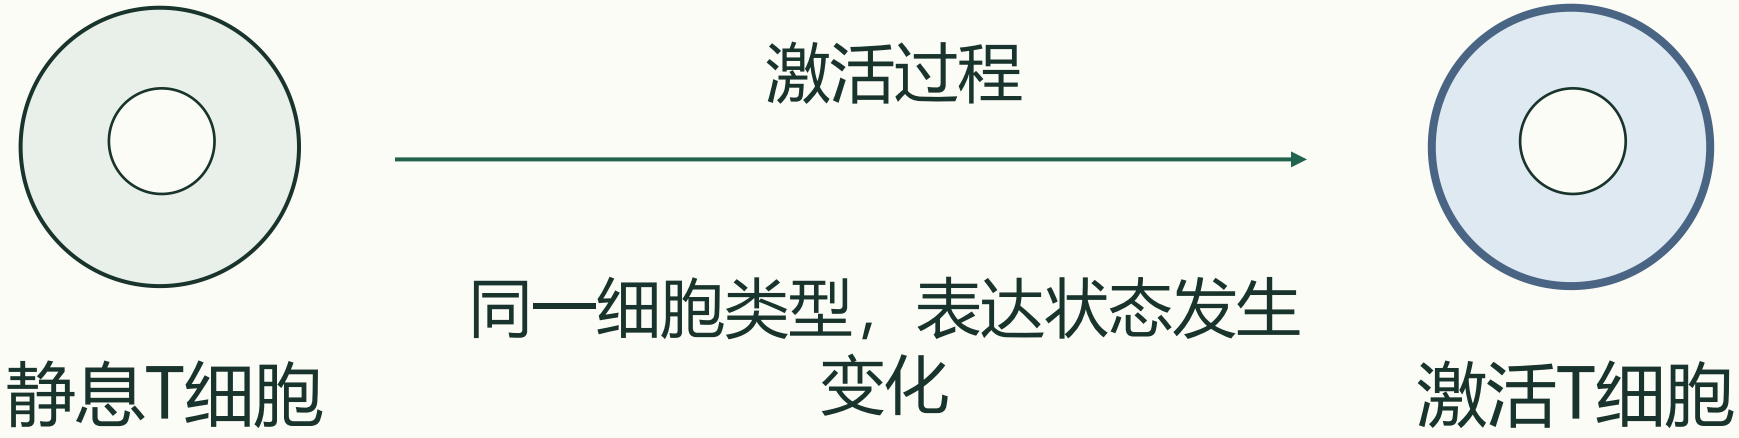
观察维度	含义	例子
细胞类型	相对稳定的身份	T细胞、B细胞
细胞状态	当前的活动状态	静息、激活、应激

同一个T细胞由静息转为激活时，细胞类型仍是T细胞。

Cui et al., Nat. Methods 2024 · Theodoris et al., Nature 2023

一个T细胞可以处于不同状态

T细胞从静息转为激活时，类型保持不变。



类型注释关注稳定身份，状态分析关注表达模式的变化

Cui et al., Nat. Methods 2024 · Theodoris et al., Nature 2023

读一张表达矩阵

每行是一个细胞，每列是一个基因。

细胞	基因A	基因B	基因C
甲细胞	8	1	0
乙细胞	1	7	0
丙细胞	3	2	6

Cui et al., Nat. Methods 2024

从计数到模型输入经历什么

按模型要求完成质控、归一化与数值编码。

阶段	处理对象	产生的结果
计数矩阵	细胞与基因的测量	每项输入的原始数值
数值处理	测量深度与值域	可比较的表达信息
模型编码	基因、数值或排序	检查点要求的token输入

Cui et al., Nat. Methods 2024 · Theodoris et al., Nature 2023

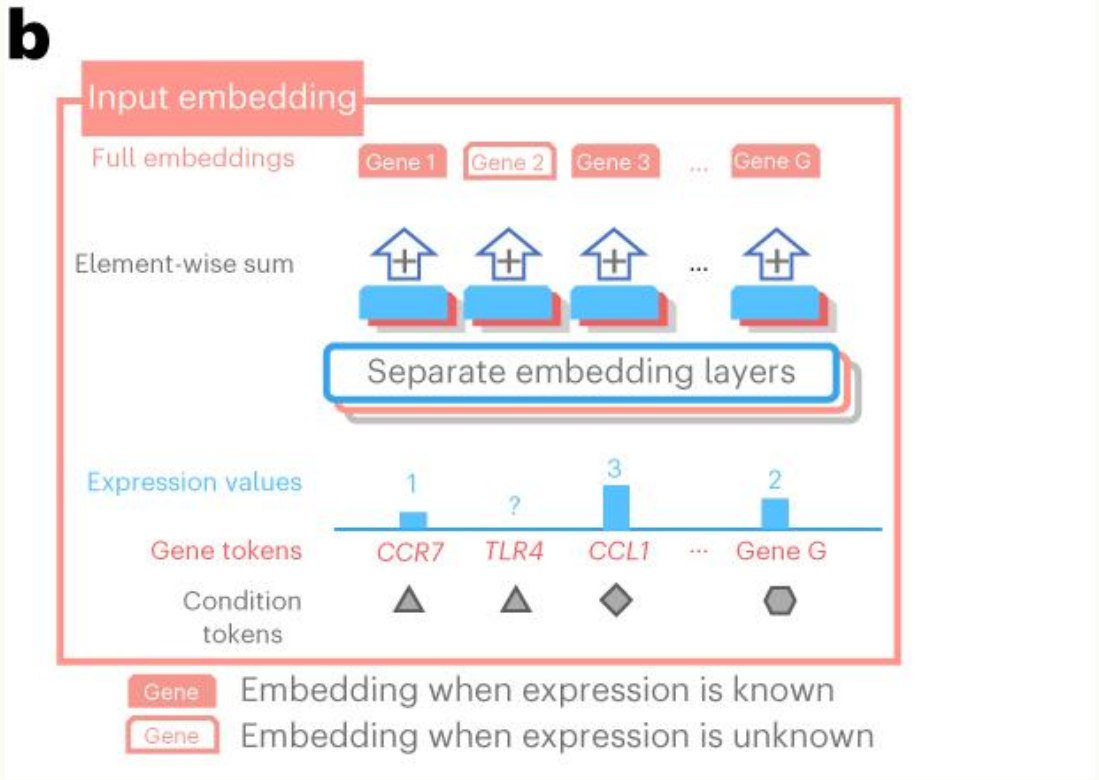
从表达矩阵到模型输入

确认基因身份、表达处理方式和测量面板。

数据步骤	需要确认	常见问题
基因标识	各列对应同一基因	别名或列顺序混淆
表达处理	符合模型训练规范	计数与归一化值混用
基因面板	未测与低表达区分	缺失被解释为生物零

Cui et al., Nat. Methods 2024

scGPT 的表示思路



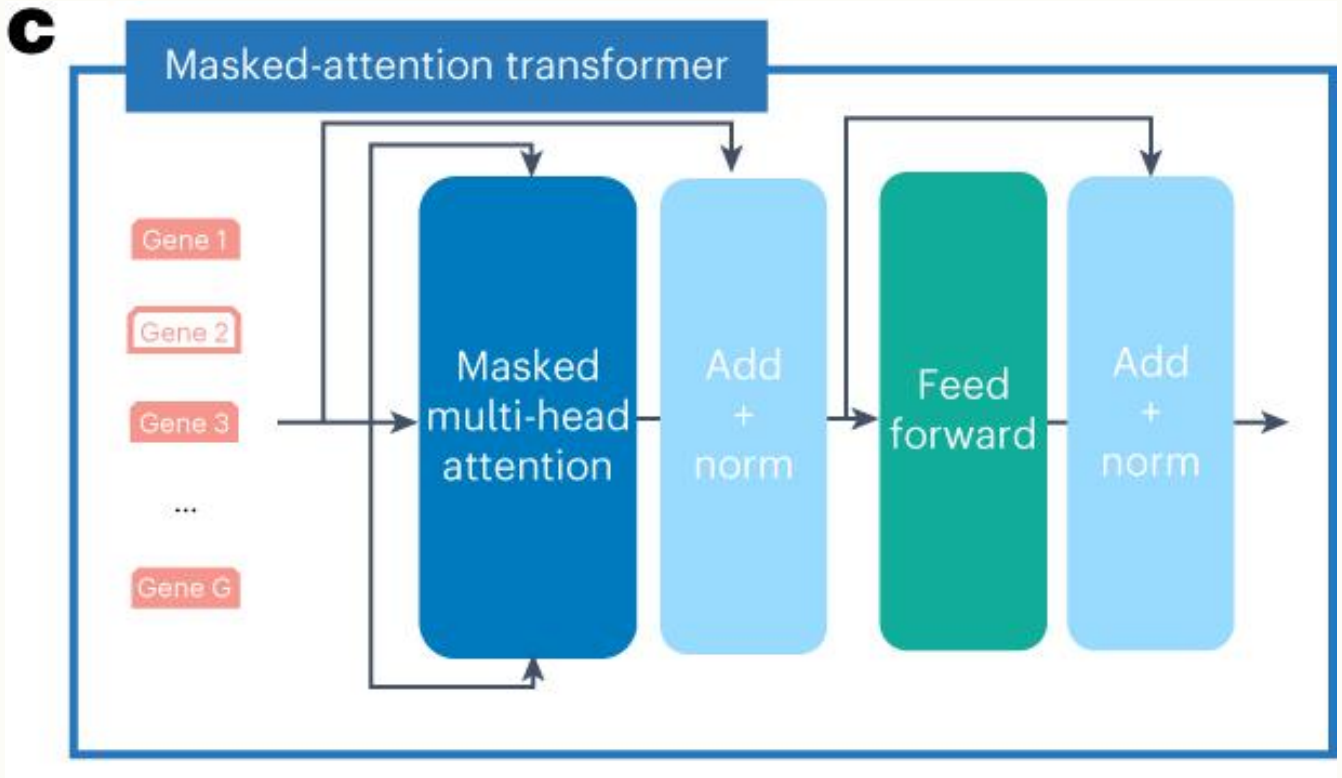
基因身份与表达值分别编码

再组合成每个基因的输入表示

输入表示由基因、表达值及条件信息组合

Cui et al., Nat. Methods 2024

遮盖表达信息怎样训练细胞表示



注意力连接可见信息，前馈网络继续变换表示

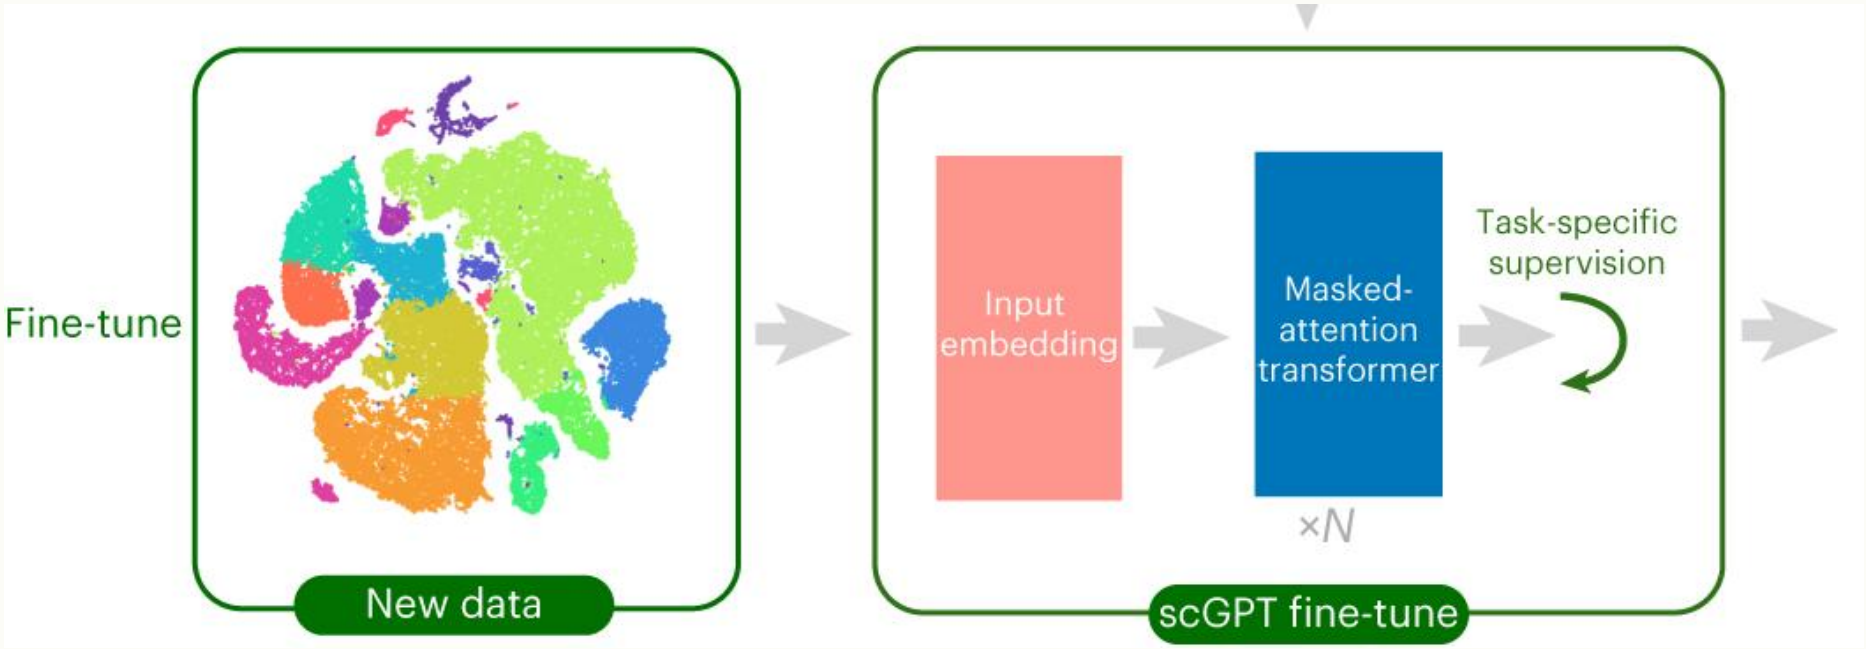
Cui et al., Nat. Methods 2024

可见基因提供上下文

注意力模块学习表达组合关系

细胞注释怎样完成

新细胞先经过同样的输入处理，再由任务头输出类型。



任务监督把预训练表示接到新的细胞数据上

Cui et al., Nat. Methods 2024

细胞注释结果的混淆矩阵

对角线是正确分类，非对角线显示容易混淆的类型。

真实标签	预测T类	预测B类
T类	8	2
B类	1	9

Cui et al., Nat. Methods 2024

Geneformer 的输入对照

Geneformer采用相对排序，scGPT编码基因身份与表达值。

维度	Geneformer	scGPT
输入重点	经处理的基因排序	基因身份与表达值
共同目标	细胞/基因表示	细胞/基因表示
比较前提	匹配数据和任务设置	匹配数据和任务设置

Theodoris et al., Nature 2023 · Cui et al., Nat. Methods 2024

把表达值转换成基因排序

先得到相对表达，再把基因排成token序列。

基因	处理后的相对表达	排序位置
A	2	2
B	5	1
C	1	3

Theodoris et al., Nature 2023

批次整合同时关注技术与生物信号



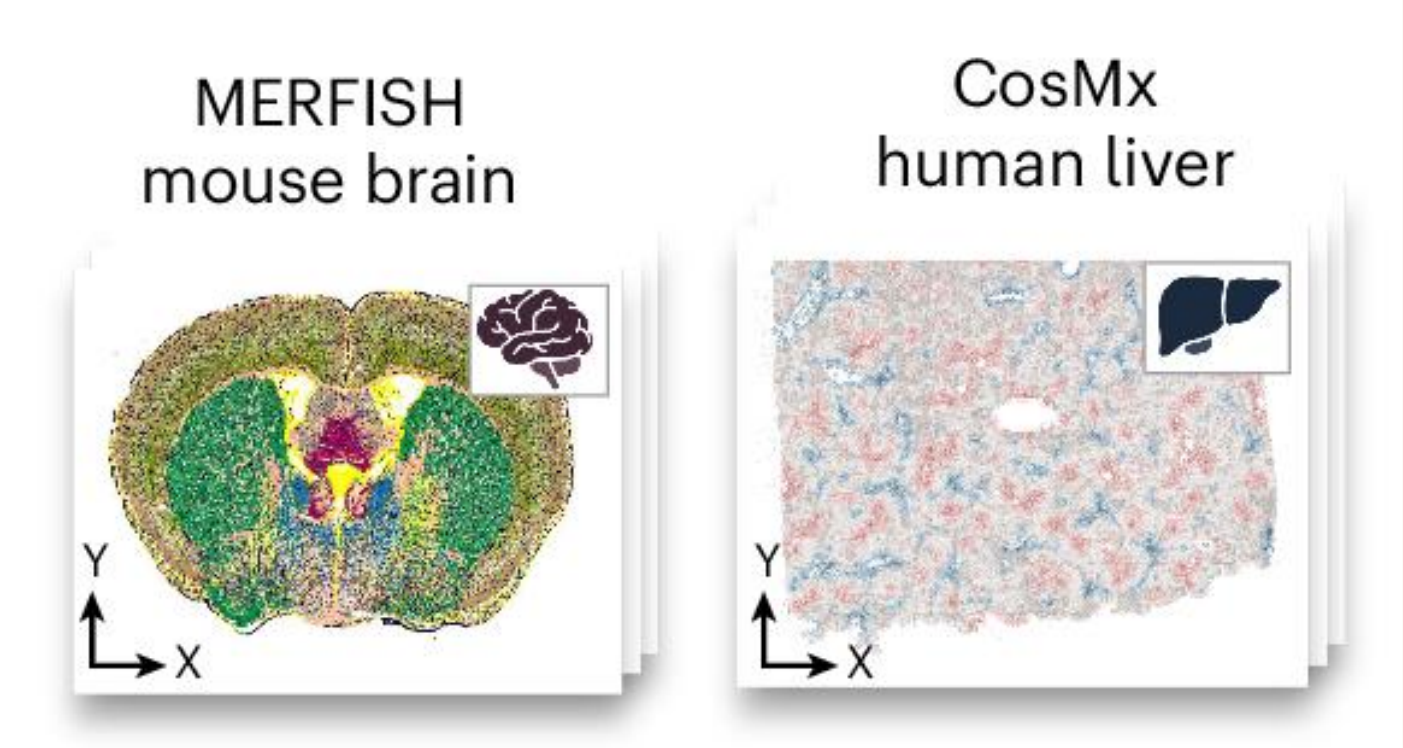
图中上方为聚类与批次校正两个下游方向

Cui et al., Nat. Methods 2024

整合时让技术批次相互混合

同时保留细胞类型等生物差异

空间转录组增加了什么



MERFISH小鼠脑与CosMx人肝的空间数据示例

Nicheformer, Nat. Methods 2025

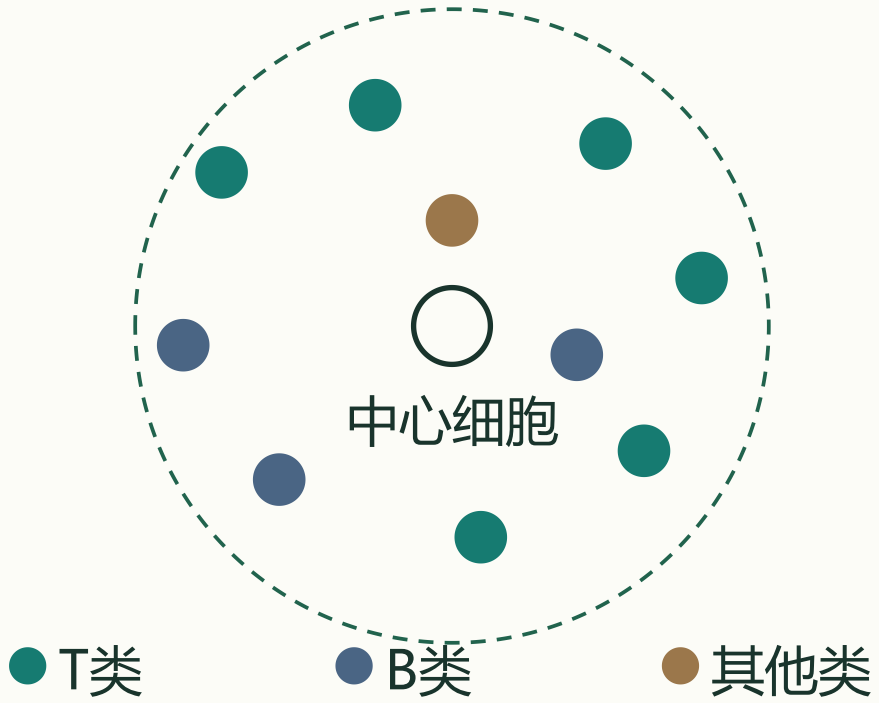
空间测量保留组织位置

表达谱由此连接到切片上的局部区域

把细胞放回组织中的位置

坐标确定中心细胞的位置

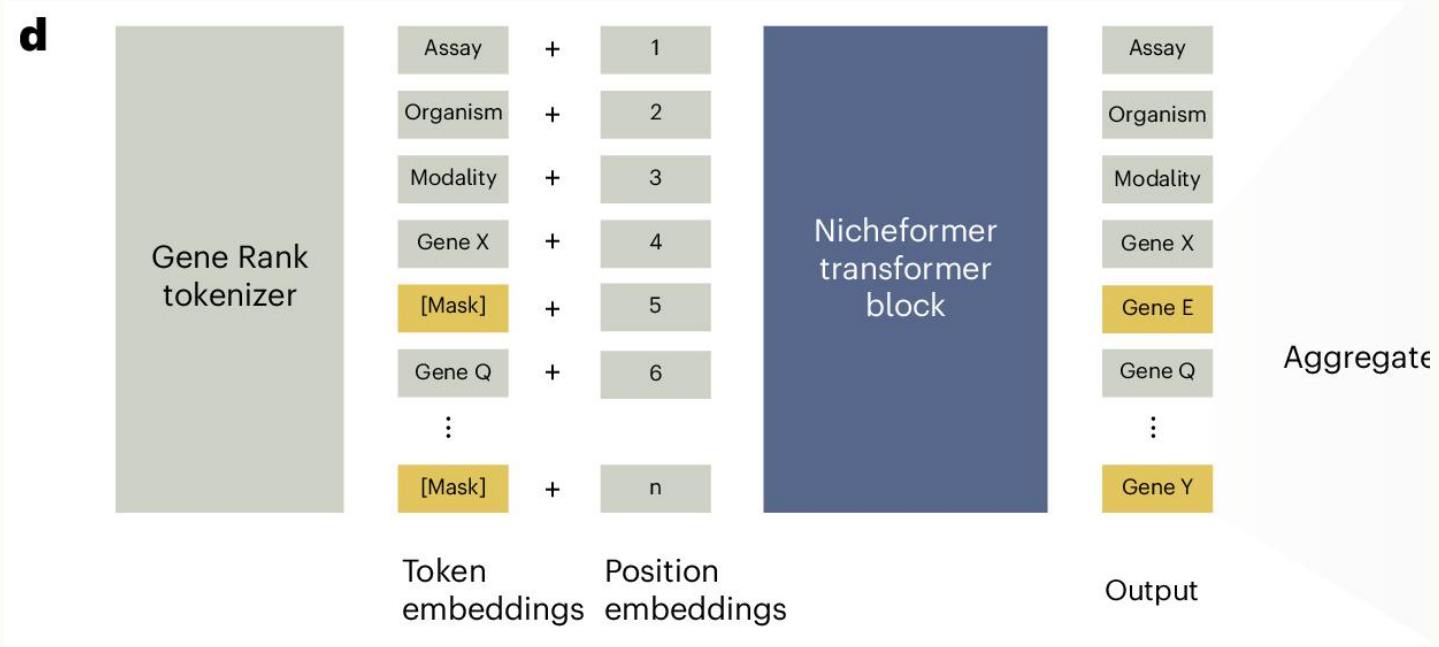
邻域规则确定纳入哪些周围细胞



Nicheformer, Nat. Methods 2025

Nicheformer 的学习与任务

排序基因与上下文标记，共同进入Nicheformer。



上下文标记在前，排序后的基因token在后

Nicheformer, Nat. Methods 2025

Nicheformer怎样标识数据来源

物种、模态和技术标记，补充表达序列的来源信息。

输入部分	携带的信息	作用
基因token	处理后的基因排序	描述细胞表达组合
物种token	人或小鼠等来源	连接共享与物种相关信息
模态 / 技术 token	解离或空间及测量技术	描述数据产生的上下文

Nicheformer, Nat. Methods 2025

从表达推测邻域组成

把邻居类型的计数转成比例，就得到邻域组成。

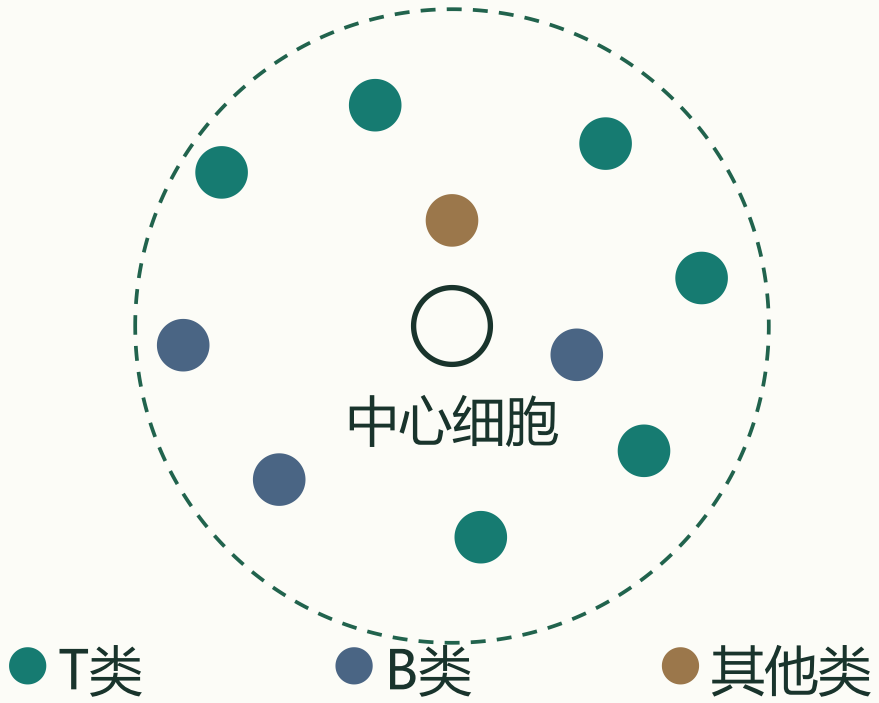
邻域	T类比例	B类比例	其他类比例
甲	0.60	0.25	0.15
乙	0.10	0.70	0.20

Nicheformer, Nat. Methods 2025

邻居计数怎样变成组成向量

10个邻居：T类6，B类3，其他1

组成向量为(0.6，0.3，0.1)



Nicheformer, Nat. Methods 2025

围绕新供体、新组织与新平台评估

评估边界与未来的数据来源保持一致。

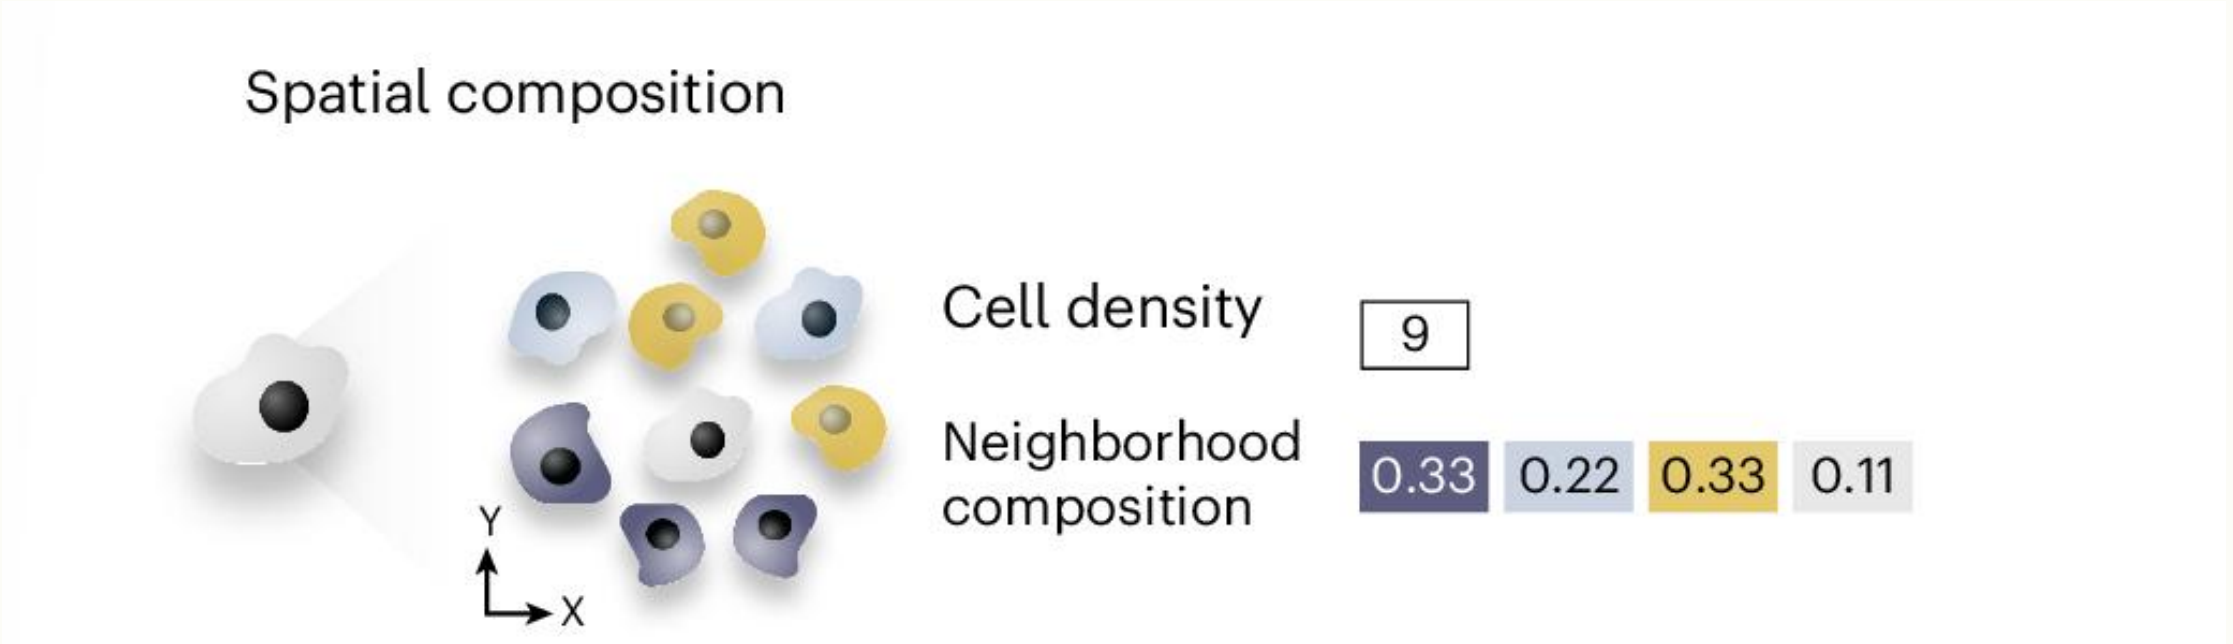
	训练时可见	测试时的新对象
供体	既有供体	新供体
组织	既有组织	新组织
平台	既有平台	新平台

分别报告新供体、新组织或新平台中的表现

单细胞模型评测, Genome Biol. 2025 · Nicheformer, Nat. Methods 2025

空间任务的输出层次

空间组成用邻居总数与各类型比例，描述中心细胞的周围环境。



细胞密度对应邻居数量，邻域组成对应各类型的比例

Nicheformer, Nat. Methods 2025

本课小结

输入	表达矩阵与编码规则
表示	scGPT、Geneformer
空间任务	Nicheformer

Cui et al., Nat. Methods 2024 · Theodoris et al., Nature 2023 等

延伸阅读

scGPT：单细胞多组学基础模型

Cui et al., Nat. Methods 2024

Geneformer：网络生物学迁移学习

Theodoris et al., Nature 2023

Nicheformer：单细胞与空间组学

Nicheformer, Nat. Methods 2025

单细胞基础模型的零样本评测

单细胞模型评测, Genome Biol. 2025