BIOLOGICAL
FOUNDATION MODELS

跨模态
与模型选型

跨核酸、蛋白质与细胞模型选型
以LucaOne连接不同序列对象

CROSS-MODAL

本课要形成一份选型说明

先根据数据对象筛选模型，再明确任务与评价。



同一种输入仍可对应多个任务，最终选型还要检查具体版本和适配方式

Wang et al., ACL 2025 · DNA模型评测, Nat. Commun. 2025 等

跨模态首先要说明跨什么

先写清楚连接了哪些生物对象，再讨论跨模态能力。

跨什么信息	讨论对象	需要明确
序列/结构/功能	ESM3	同一蛋白的不同描述
核酸/蛋白质	LucaOne	不同分子对象的关联
细胞多组学	研究方向	测量配对与输入条件

EvolutionaryScale, ESM3 · LucaOne, Nat. Mach. Intell. 2025 等

核酸与蛋白质怎样描述同一个产物

编码DNA经转录成为mRNA，密码子再对应到氨基酸。

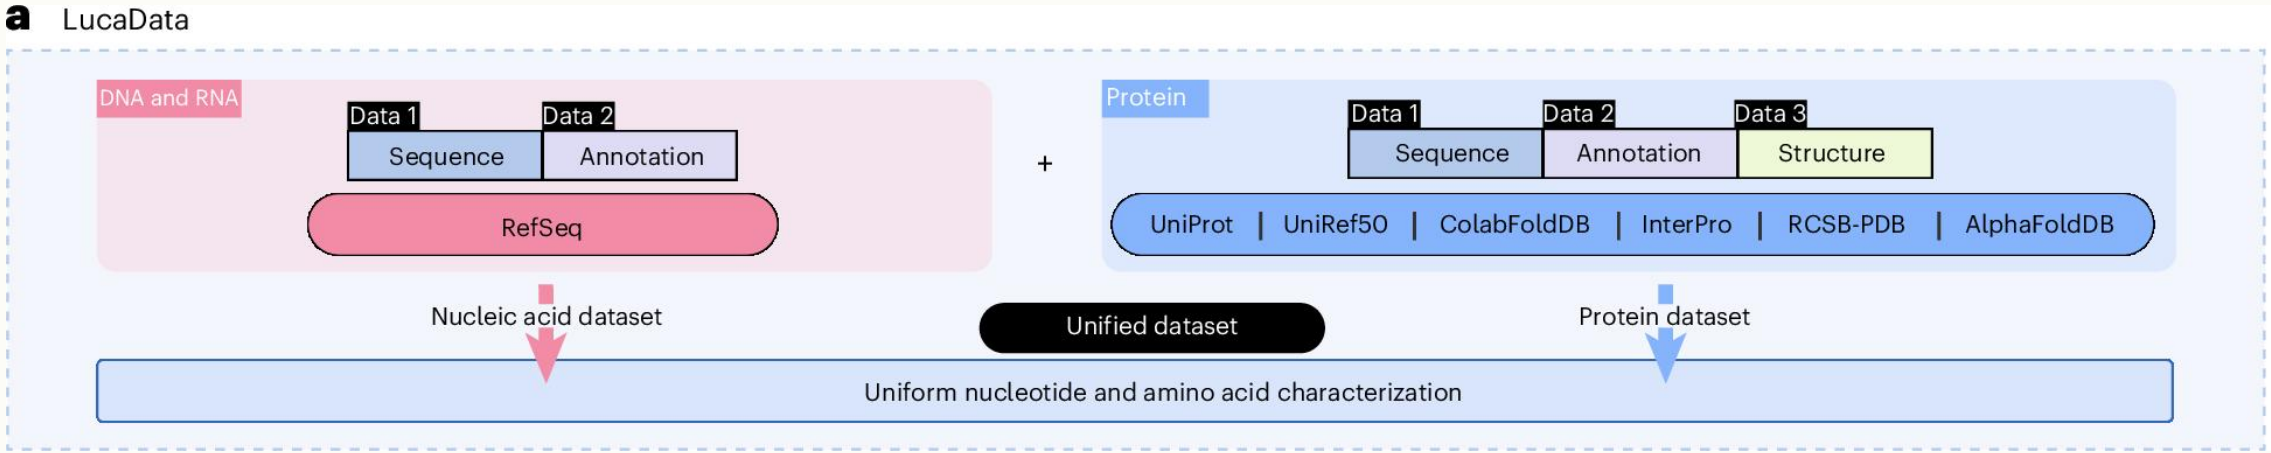
编码DNA	ATG	AAA	ACC
	↓		
mRNA	AUG	AAA	ACC
	↓		
蛋白质	**M**	**K**	**T**

ATG / AUG对应M，AAA对应K，ACC对应T

LucaOne, Nat. Mach. Intell. 2025

LucaOne 的建模范围

LucaOne联合学习核酸与蛋白质序列。用统一模型得到可迁移表示。

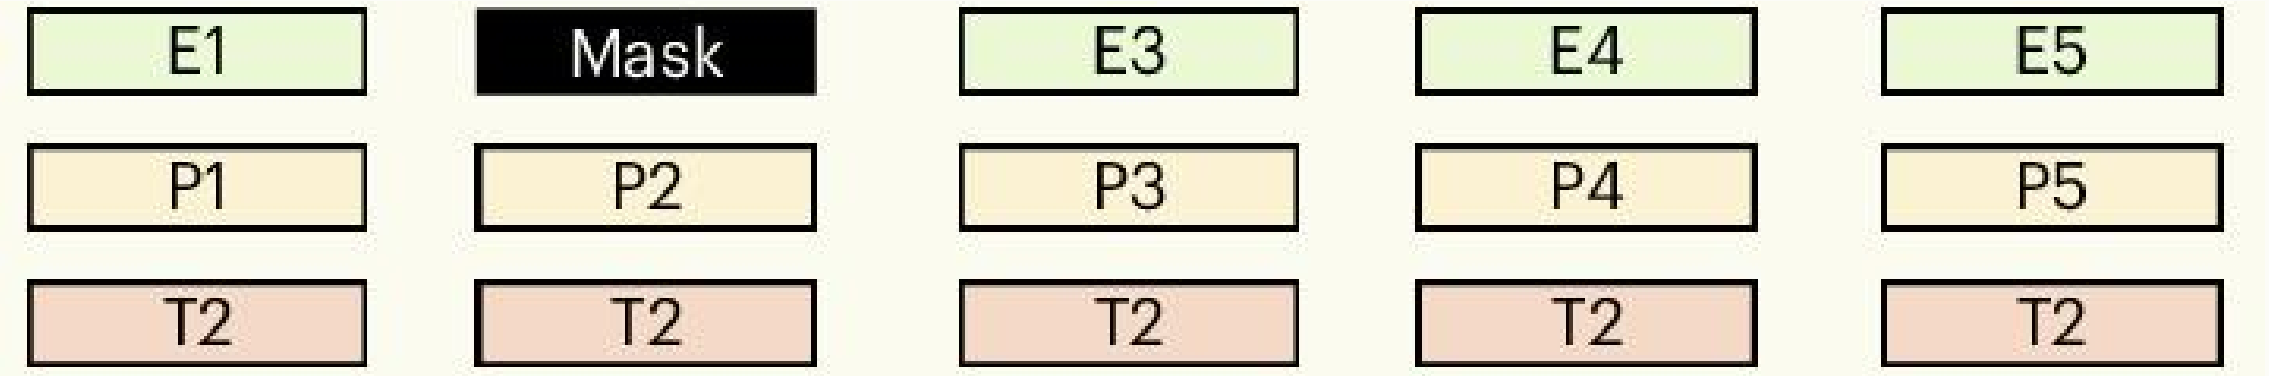


核酸与蛋白质数据汇入统一的序列表示学习

LucaOne, Nat. Mach. Intell. 2025

LucaOne的统一输入由什么组成

字符、位置与分子类型嵌入，共同构成模型输入。



E表示字符嵌入，P表示位置，T表示分子类型

LucaOne, Nat. Mach. Intell. 2025

“联合”怎样得到检验

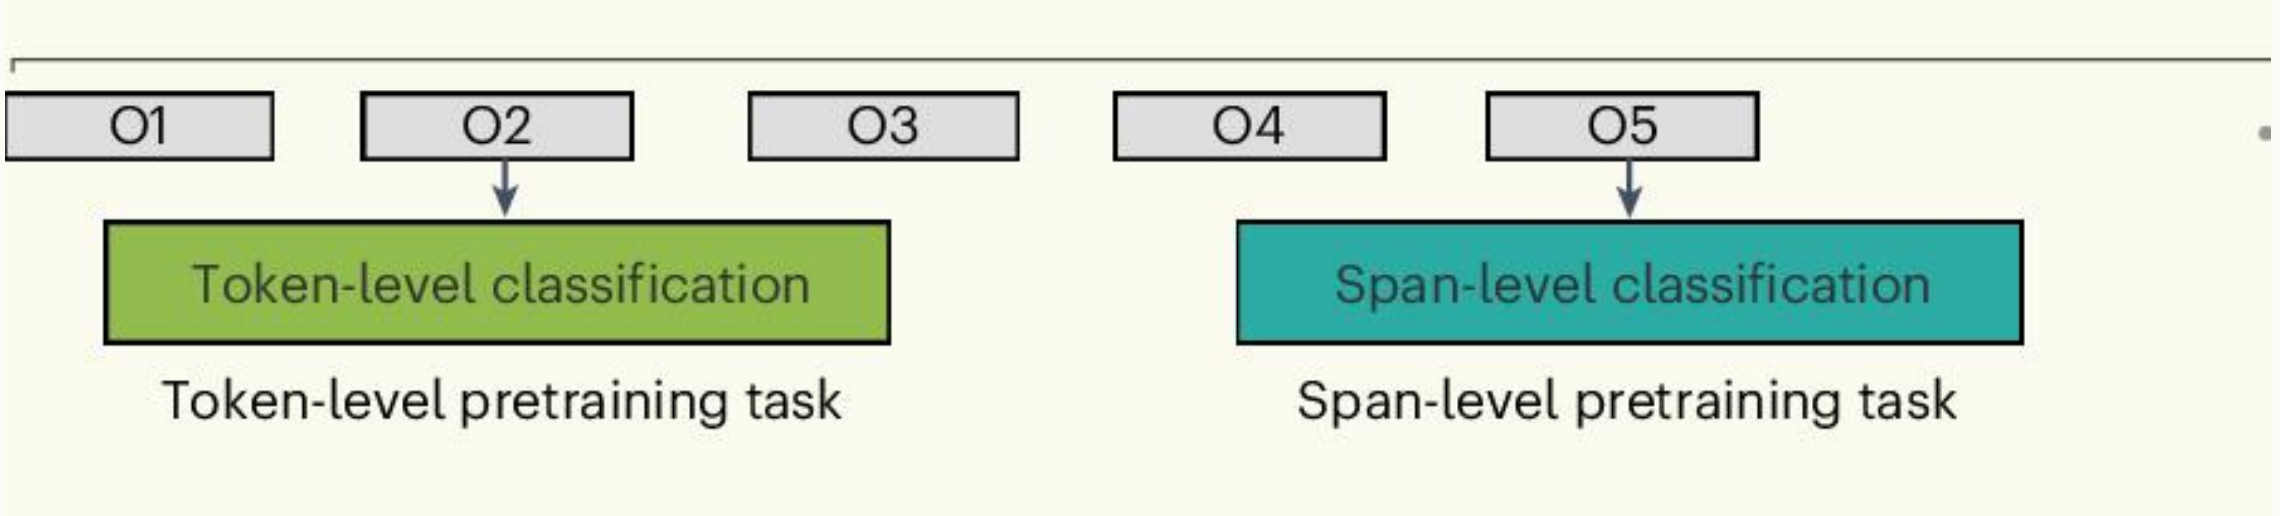
比较联合学习效果时，固定数据划分和任务头。

比较方案	表示来自哪里	保持一致
分别学习	核酸/蛋白模型	下游数据与标签量
联合学习	统一模型	任务头与评价划分
简单基线	基础编码或统计量	同一目标与指标

LucaOne, Nat. Mach. Intell. 2025

LucaOne怎样组织多层次训练信号

局部字符恢复与片段分类，提供不同层次的训练信号。



输出向量可连接token级与片段级分类头

LucaOne, Nat. Mach. Intell. 2025

按输入对象整理整张模型地图

按生物对象与目标输出组织模型地图。

研究对象	典型输入	代表模型
DNA/RNA	核酸序列	NT / Evo 2 / RiNALMo
蛋白质	序列、结构或功能	ESM3 / AlphaFold 3
细胞	表达与上下文	scGPT / Nicheformer

Wang et al., ACL 2025 · 组学基础模型综述, 2026 等

把研究问题转换成输入—输出接口

分类、回归和结构任务，需要不同形式的输出。

分类	回归	结构
T细胞 / B细胞	$\hat{y}$	(x, y, z)
离散类别	活性或表达数值	空间坐标

先明确要得到类别、数值还是坐标，再确定任务接口

Wang et al., ACL 2025 · LucaOne, Nat. Mach. Intell. 2025

变异评分的模型选型

参考与变异序列采用相同窗口和分词设置。



$$\Delta S = S(alt) - S(ref)$$

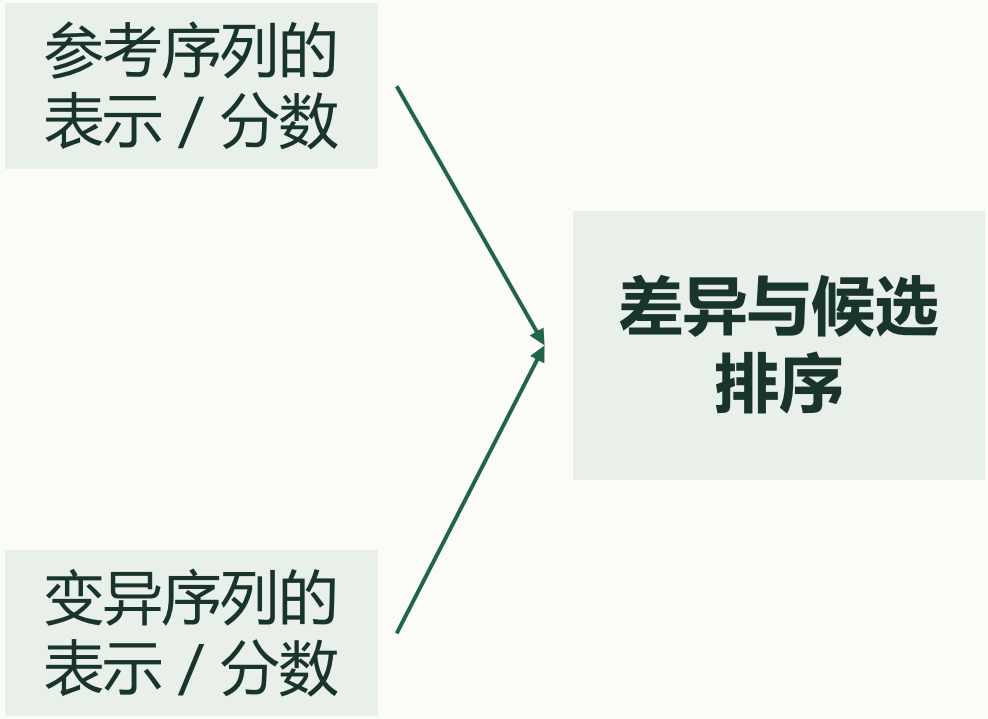
得分差用于比较候选，具体得分定义取决于模型和研究任务

Dalla-Torre et al., Nat. Methods 2025 · Evo 2, Nature 2026 等

变异比较怎样构成一个评分接口

表示差异、任务得分、序列概率

分别形成可比较的变异评分



Dalla-Torre et al., Nat. Methods 2025 · Evo 2, Nature 2026 等

细胞注释的模型选型

参考标签用于适配分类头，新细胞经同样的编码后得到注释。

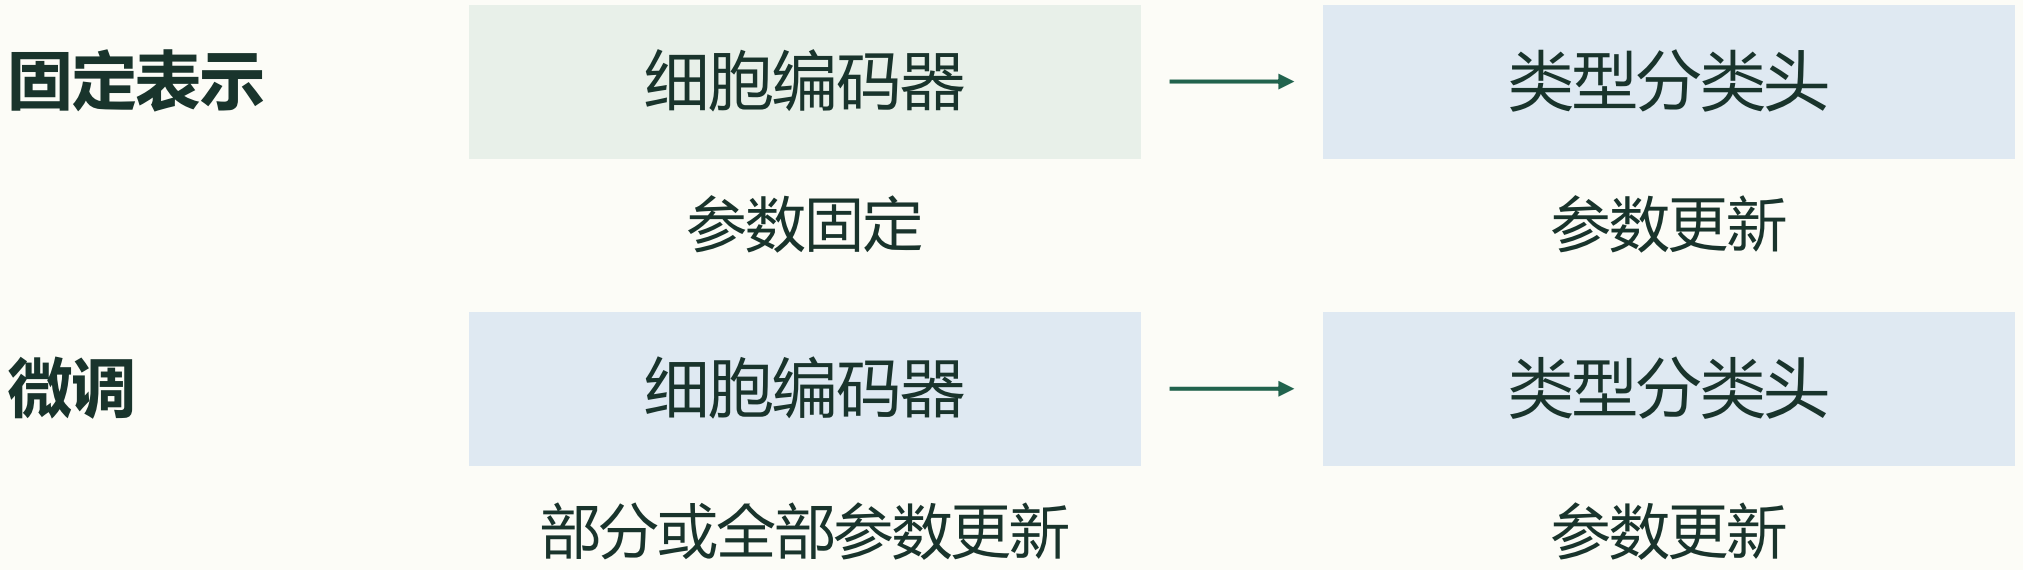


训练与推断分开组织，测试细胞来自独立样本

Cui et al., Nat. Methods 2024 · Theodoris et al., Nature 2023 等

标签与资源怎样影响细胞任务适配

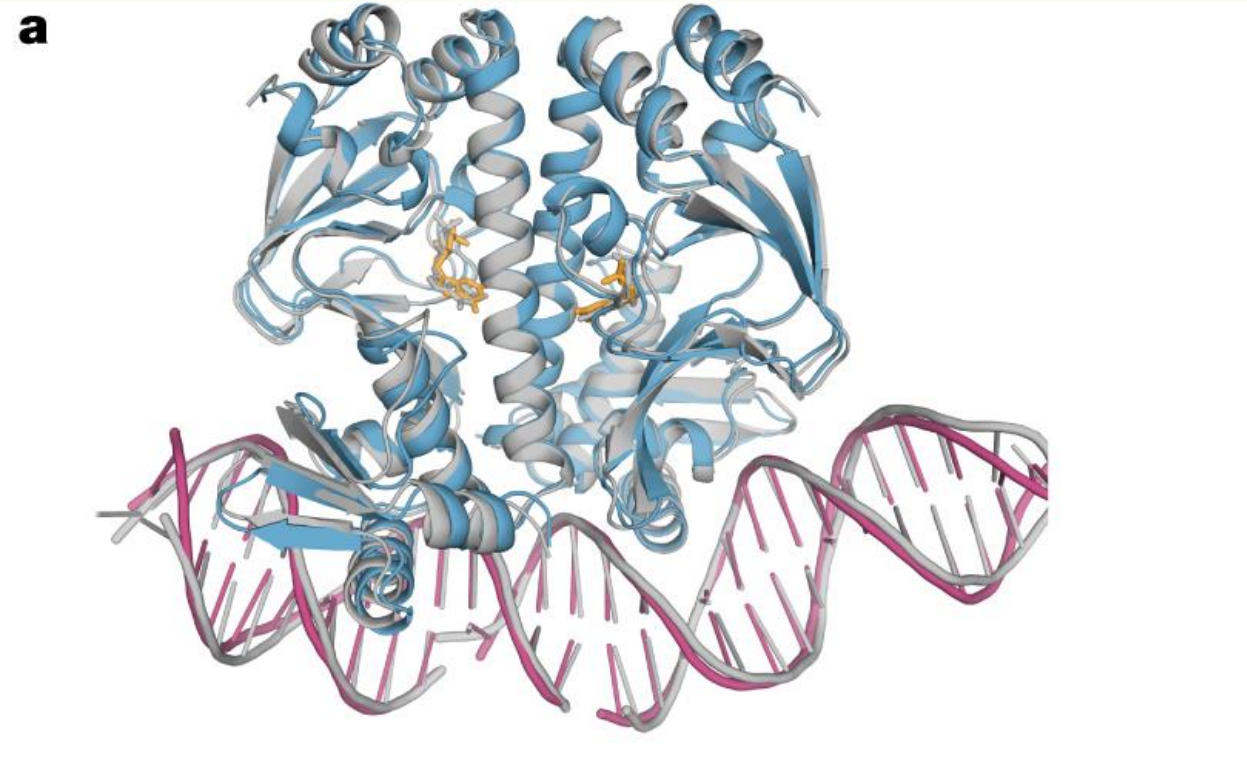
适配方式决定编码器是否参与参数更新。



固定表示只训练任务头；微调同时更新部分或全部编码器

Cui et al., Nat. Methods 2024 · 单细胞模型评测, Genome Biol. 2025

复合物结构的模型选型



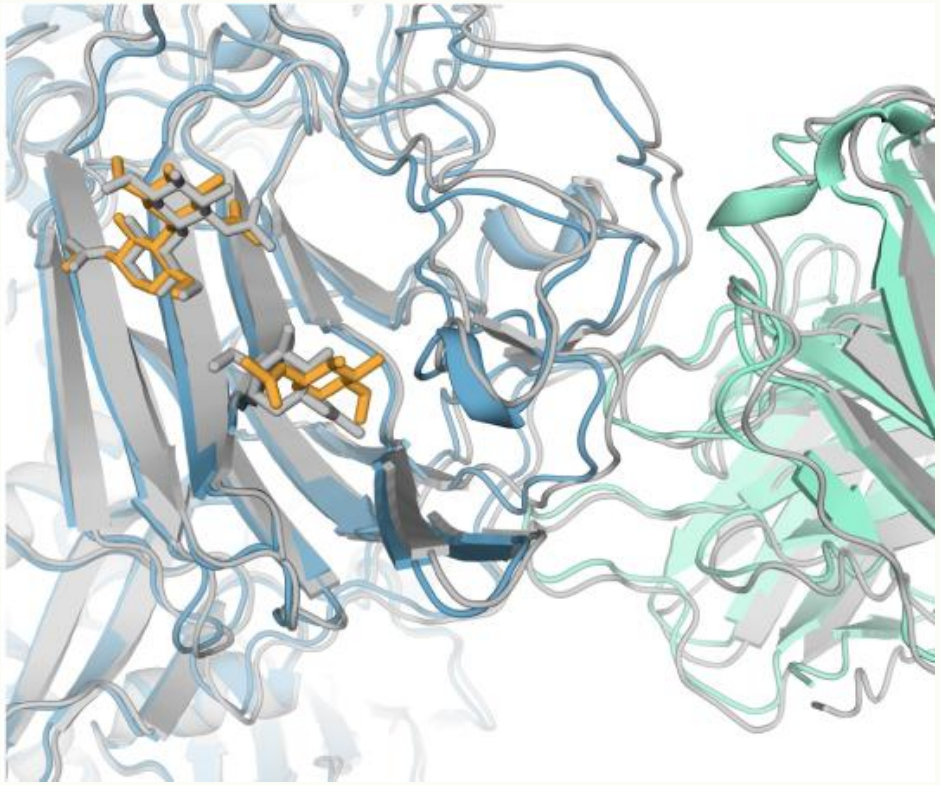
输入明确的分子组分

定位候选的接触区域

输入链与分子身份决定后续界面阅读的对象

Abramson et al., Nature 2024

从坐标到界面特征还要做什么



在局部构象中定位接触残基与配体

Abramson et al., Nature 2024

定位配体周围的残基

把接触区域映射回序列位置

任务不同，比较项也不同

不同研究目标，对应不同输入、输出与评价对象。

任务	输入	要检查的证据
变异评分	核酸序列对	独立标签与划分
细胞注释	表达矩阵	跨样本标签表现
结构预测	分子组分	结构与界面质量

DNA模型评测, Nat. Commun. 2025 · 单细胞模型评测, Genome Biol. 2025 等

零样本、探测与微调

零样本、线性探针与微调，使用不同标签和参数更新范围。

适配方式	更新什么	目标任务训练
零样本	不更新模型	不使用目标任务标签
线性探测	仅训练线性任务头	使用目标任务标签
微调	部分或全部模型	按任务训练与验证

DNA模型评测, Nat. Commun. 2025 · 单细胞模型评测, Genome Biol. 2025

选型还要记录运行成本与复用条件

记录资源开销与关键配置，方便复现同一研究流程。

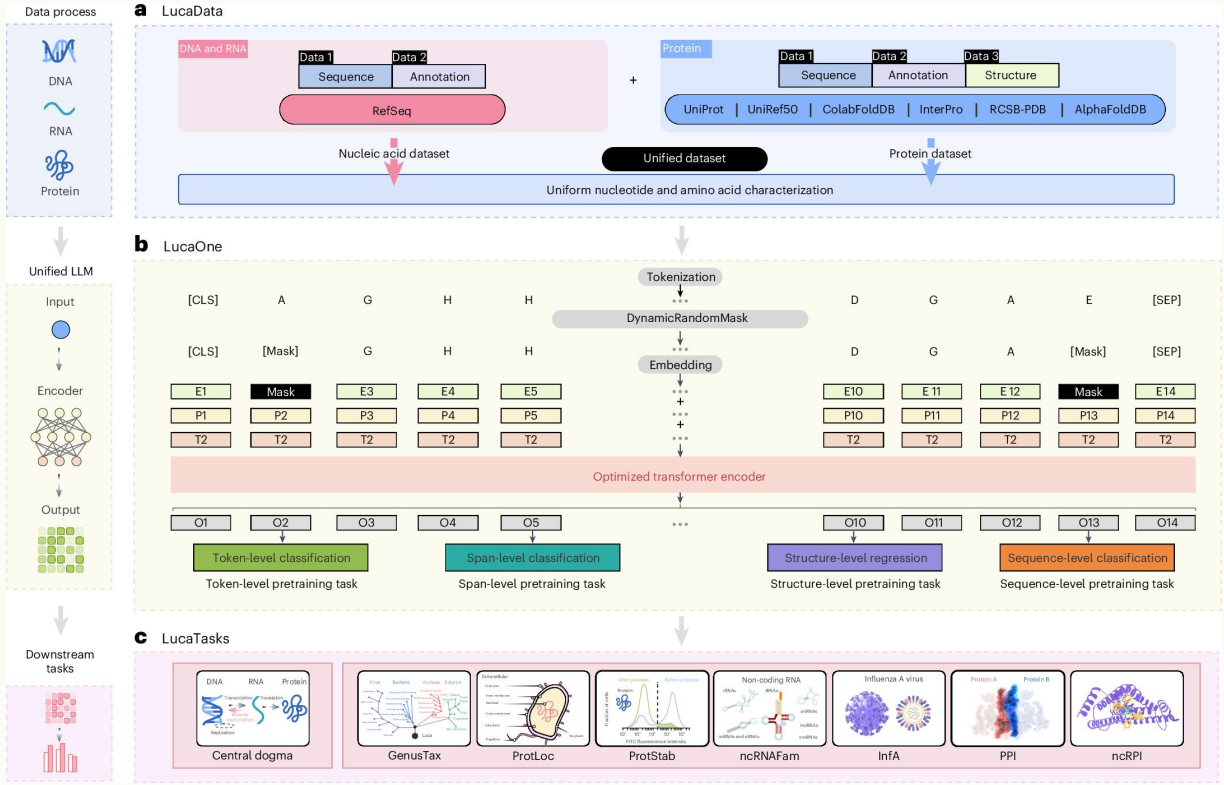
记录项	为什么需要	怎样比较
数据与窗口	决定一次输入的规模	固定任务后比较配置
模型与适配	决定参数更新和资源需求	记录检查点与更新范围
运行与结果	复查和再次运行的条件	保留环境、耗时和输出

把模型接入可追溯工作流

把结果与产生它的数据、模型和配置对应保存。

记录对象	保留的信息
数据	来源与预处理版本
模型	检查点与分词设置
推断	窗口、批次与采样配置
结果	输出、指标及运行环境

读一篇新论文时先找这三组信息



上部：训练数据及其组合

中部：输入表示与训练目标

下部列出下游任务；读图时把数据、训练与应用对应起来

LucaOne, Nat. Mach. Intell. 2025

三种研究需求的选型结果

三种研究需求，分别形成可执行的模型方案。

研究需求	模型路线	读取结果
DNA变异	NT / Evo 2	表示或序列得分
细胞注释	scGPT	细胞类型
复合物结构	AlphaFold 3	坐标与接触区域

Wang et al., ACL 2025 · DNA模型评测, Nat. Commun. 2025 等

整门课程回顾

对象

序列、蛋白质、细胞有不同输入

选型

统一按数据、模型、适配和评价选型

Wang et al., ACL 2025 · Dalla-Torre et al., Nat. Methods 2025 等

延伸阅读与后续专题

LucaOne：统一核酸与蛋白质语言

LucaOne, Nat. Mach. Intell. 2025

生物信息大模型综述

Wang et al., ACL 2025

组学基础模型综述

组学基础模型综述, 2026

分子细胞生物学的跨模态基础模型

多模态细胞模型展望, Nature 2025

OneScience：科学计算与领域模型入口

光合开发者社区 OneScience